

La Classification


Apprendre à catégoriser - Pas à pas

Joseph Azar

Maître de conférences
Université Marie Louis Pasteur
Intelligence Artificielle - Semaine 4



Commençons par un jeu...





Commençons par un jeu...

Imaginez que vous montrez des photos à un enfant:



Commençons par un jeu...

Imaginez que vous montrez des photos à un enfant:

 "Ça c'est un chat" → 10 photos de chats



Commençons par un jeu...

Imaginez que vous montrez des photos à un enfant:



"Ça c'est un chat" → 10 photos de chats



"Ça c'est un chien" → 10 photos de chiens



Commençons par un jeu...

Imaginez que vous montrez des photos à un enfant:

 "Ça c'est un chat" → 10 photos de chats

 "Ça c'est un chien" → 10 photos de chiens

Ensuite, vous montrez une nouvelle photo...



Commençons par un jeu...

Imaginez que vous montrez des photos à un enfant:



"Ça c'est un chat" → 10 photos de chats



"Ça c'est un chien" → 10 photos de chiens

Ensuite, vous montrez une nouvelle photo...

L'enfant peut dire si c'est un chat ou un chien! 🎯



Commençons par un jeu...

Imaginez que vous montrez des photos à un enfant:



"Ça c'est un chat" → 10 photos de chats



"Ça c'est un chien" → 10 photos de chiens

Ensuite, vous montrez une nouvelle photo...

L'enfant peut dire si c'est un chat ou un chien! 🎯



C'est exactement ça, la **classification**!

Apprendre à partir d'exemples pour ranger dans des catégories

Qu'est-ce que la Classification?

Définition: La classification est une technique d'apprentissage supervisé qui prédit une **catégorie** (classe) pour une nouvelle donnée

Qu'est-ce que la Classification?

Définition: La classification est une technique d'apprentissage supervisé qui prédit une **catégorie** (classe) pour une nouvelle donnée

Objectif

Prédire une **catégorie discrète**

Ex: chat/chien, spam/normal, malade/sain

Différence avec régression

Régression → valeur continue (prix, température)

Classification → catégorie (oui/non, A/B/C)

Plan de la présentation

Plan de la présentation

1. 🤔 Qu'est-ce que la classification?

Plan de la présentation

1. 🤔 Qu'est-ce que la classification?
2. 🌍 Cas d'usage dans la vie réelle

Plan de la présentation

1. 🤔 Qu'est-ce que la classification?
2. 🌐 Cas d'usage dans la vie réelle
3. 📊 Les types de classification

Plan de la présentation

1. 🤔 Qu'est-ce que la classification?
2. 🌐 Cas d'usage dans la vie réelle
3. 📊 Les types de classification
4. ♟️ Calcul manuel étape par étape

Plan de la présentation

1. 🤔 Qu'est-ce que la classification?
2. 🌐 Cas d'usage dans la vie réelle
3. 📊 Les types de classification
4. ♟️ Calcul manuel étape par étape
5. 🎯 K-Nearest Neighbors (KNN) - Simple!

Plan de la présentation

1. 🤔 Qu'est-ce que la classification?
2. 🌍 Cas d'usage dans la vie réelle
3. 📊 Les types de classification
4. ♟️ Calcul manuel étape par étape
5. 🎯 K-Nearest Neighbors (KNN) - Simple!
6. 📈 Régression Logistique

Plan de la présentation

1. 🤔 Qu'est-ce que la classification?
2. 🌐 Cas d'usage dans la vie réelle
3. 📊 Les types de classification
4. ♟️ Calcul manuel étape par étape
5. 🎯 K-Nearest Neighbors (KNN) - Simple!
6. 📈 Régression Logistique
7. 🌳 Arbres de décision

Plan de la présentation

1. 🤔 Qu'est-ce que la classification?
2. 🌐 Cas d'usage dans la vie réelle
3. 📊 Les types de classification
4. ♟️ Calcul manuel étape par étape
5. 🎯 K-Nearest Neighbors (KNN) - Simple!
6. 📈 Régression Logistique
7. 🌳 Arbres de décision
8. 📏 Mesurer les performances

Applications dans la vie réelle

Email & Sécurité

- Spam ou pas spam?
- Fraude bancaire?
- Reconnaissance faciale

Médecine

- Cancer bénin ou malin?
- Diagnostic de maladies
- Classification de symptômes

Multimédia

- Reconnaissance d'images
- Classification de texte
- Analyse de sentiments

Business

- Client va acheter?
- Prêt: risqué ou pas?
- Produit défectueux?



Les types de classification

1 Classification Binaire (2 classes)

Oui/Non, Vrai/Faux, 0/1



Les types de classification

1 Classification Binaire (2 classes)

Oui/Non, Vrai/Faux, 0/1

Ex: Email spam? (oui/non) | Patient malade? (oui/non)



Les types de classification

1 Classification Binaire (2 classes)

Oui/Non, Vrai/Faux, 0/1

Ex: Email spam? (oui/non) | Patient malade? (oui/non)

2 Classification Multi-classe (>2 classes)

Plusieurs catégories possibles



Les types de classification

1 Classification Binaire (2 classes)

Oui/Non, Vrai/Faux, 0/1

Ex: Email spam? (oui/non) | Patient malade? (oui/non)

2 Classification Multi-classe (>2 classes)

Plusieurs catégories possibles

Ex: Chiffre manuscrit (0-9) | Type de fleur (iris, rose, tulipe)



Les types de classification

1 Classification Binaire (2 classes)

Oui/Non, Vrai/Faux, 0/1

Ex: Email spam? (oui/non) | Patient malade? (oui/non)

2 Classification Multi-classe (>2 classes)

Plusieurs catégories possibles

Ex: Chiffre manuscrit (0-9) | Type de fleur (iris, rose, tulipe)

3 Classification Multi-label

Plusieurs étiquettes en même temps



Les types de classification

1 Classification Binaire (2 classes)

Oui/Non, Vrai/Faux, 0/1

Ex: Email spam? (oui/non) | Patient malade? (oui/non)

2 Classification Multi-classe (>2 classes)

Plusieurs catégories possibles

Ex: Chiffre manuscrit (0-9) | Type de fleur (iris, rose, tulipe)

3 Classification Multi-label

Plusieurs étiquettes en même temps

Ex: Photo avec chat ET chien | Film (action ET romance)

Exemple: Classifier des fruits

Objectif: Distinguer pommes  et oranges 

Fruit	Poids (g)	Diamètre (cm)	Couleur (0-100)	Classe
1	150	7	10	Pomme 
2	170	7.5	15	Pomme 
3	140	8	85	Orange 
4	130	7.5	90	Orange 

Exemple: Classifier des fruits

Objectif: Distinguer pommes  et oranges 

Fruit	Poids (g)	Diamètre (cm)	Couleur (0-100)	Classe
1	150	7	10	Pomme 
2	170	7.5	15	Pomme 
3	140	8	85	Orange 
4	130	7.5	90	Orange 
?	145	7.2	12	?

Exemple: Classifier des fruits

Objectif: Distinguer pommes  et oranges 

Fruit	Poids (g)	Diamètre (cm)	Couleur (0-100)	Classe
1	150	7	10	Pomme 
2	170	7.5	15	Pomme 
3	140	8	85	Orange 
4	130	7.5	90	Orange 
?	145	7.2	12	?

 Comment décider? On va voir plusieurs méthodes!



KNN - L'algorithme le plus simple!

Idée: "Dis-moi qui sont tes voisins, je te dirai qui tu es"



KNN - L'algorithme le plus simple!

Idée: "Dis-moi qui sont tes voisins, je te dirai qui tu es"

Principe en 3 étapes:

1. Trouver les K points les plus **proches** du nouveau point
2. Regarder leurs **classes**
3. Choisir la classe **majoritaire**



KNN - L'algorithme le plus simple!

Idée: "Dis-moi qui sont tes voisins, je te dirai qui tu es"

Principe en 3 étapes:

1. Trouver les K points les plus **proches** du nouveau point
2. Regarder leurs **classes**
3. Choisir la classe **majoritaire**

Exemple: $K=3$, je regarde mes 3 voisins les plus proches

Si 2 sont des pommes et 1 est une orange → C'est une pomme!



KNN - Calculons ensemble!



Nouveau fruit: Poids=145g, Diamètre=7.2cm, Couleur=12

$K = 3$ (on regarde les 3 voisins les plus proches)



KNN - Calculons ensemble!



Nouveau fruit: Poids=145g, Diamètre=7.2cm, Couleur=12

K = 3 (on regarde les 3 voisins les plus proches)

Étape 1: Calculer les distances

$$\text{Distance} = \sqrt{[(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2]}$$



KNN - Calculons ensemble!



Nouveau fruit: Poids=145g, Diamètre=7.2cm, Couleur=12

K = 3 (on regarde les 3 voisins les plus proches)

Étape 1: Calculer les distances

$$\text{Distance} = \sqrt{[(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2]}$$

Fruit	Calcul distance	Distance	Classe
1	$\sqrt{[(150-145)^2 + (7-7.2)^2 + (10-12)^2]}$	5.48	Pomme 🍏
2	$\sqrt{[(170-145)^2 + (7.5-7.2)^2 + (15-12)^2]}$	25.11	Pomme 🍏
3	$\sqrt{[(140-145)^2 + (8-7.2)^2 + (85-12)^2]}$	73.05	Orange 🍊
4	$\sqrt{[(130-145)^2 + (7.5-7.2)^2 + (90-12)^2]}$	78.43	Orange 🍊

KNN - Le verdict!

Étape 2: Trier par distance (du plus proche au plus loin)

1. Fruit 1: 5.48 → 🍏 Pomme
2. Fruit 2: 25.11 → 🍏 Pomme
3. Fruit 3: 73.05 → 🍊 Orange
4. Fruit 4: 78.43 → 🍊 Orange

KNN - Le verdict!

Étape 2: Trier par distance (du plus proche au plus loin)

1. Fruit 1: 5.48 → 🍏 Pomme
2. Fruit 2: 25.11 → 🍏 Pomme
3. Fruit 3: 73.05 → 🍊 Orange
4. Fruit 4: 78.43 → 🍊 Orange

Étape 3: K=3, on garde les 3 plus proches

- ✅ Pomme (distance 5.48)
- ✅ Pomme (distance 25.11)
- ✅ Orange (distance 73.05)

KNN - Le verdict!

Étape 2: Trier par distance (du plus proche au plus loin)

1. Fruit 1: 5.48 → 🍏 Pomme
2. Fruit 2: 25.11 → 🍏 Pomme
3. Fruit 3: 73.05 → 🍊 Orange
4. Fruit 4: 78.43 → 🍊 Orange

Étape 3: K=3, on garde les 3 plus proches

- ✅ Pomme (distance 5.48)
- ✅ Pomme (distance 25.11)
- ✅ Orange (distance 73.05)

Vote majoritaire: 2 pommes vs 1 orange

 **Résultat: C'est une POMME!** 🍏

À vous de jouer! KNN

 **Exercice:** Animal domestique ou sauvage?

Animal	Taille (cm)	Poids (kg)	Type
Chat	30	4	Domestique 🏠
Chien	50	15	Domestique 🏠
Loup	80	35	Sauvage 🌲
Renard	60	7	Sauvage 🌲

À vous de jouer! KNN

 **Exercice:** Animal domestique ou sauvage?

Animal	Taille (cm)	Poids (kg)	Type
Chat	30	4	Domestique 🏠
Chien	50	15	Domestique 🏠
Loup	80	35	Sauvage 🌲
Renard	60	7	Sauvage 🌲
?	40	8	?

À vous de jouer! KNN

 **Exercice:** Animal domestique ou sauvage?

Animal	Taille (cm)	Poids (kg)	Type
Chat	30	4	Domestique 🏠
Chien	50	15	Domestique 🏠
Loup	80	35	Sauvage 🌲
Renard	60	7	Sauvage 🌲
?	40	8	?

Calculez avec $K=3$ et trouvez la classe!

À vous de jouer! KNN

 **Exercice:** Animal domestique ou sauvage?

Animal	Taille (cm)	Poids (kg)	Type
Chat	30	4	Domestique 🏠
Chien	50	15	Domestique 🏠
Loup	80	35	Sauvage 🌲
Renard	60	7	Sauvage 🌲
?	40	8	?

Calculez avec K=3 et trouvez la classe!

💡 Réponse: Distances → Chat(10.2), Chien(11.4), Renard(20.1), Loup(50.9)

À vous de jouer! KNN

 **Exercice:** Animal domestique ou sauvage?

Animal	Taille (cm)	Poids (kg)	Type
Chat	30	4	Domestique 🏠
Chien	50	15	Domestique 🏠
Loup	80	35	Sauvage 🌲
Renard	60	7	Sauvage 🌲
?	40	8	?

Calculez avec K=3 et trouvez la classe!

💡 Réponse: Distances → Chat(10.2), Chien(11.4), Renard(20.1), Loup(50.9)

K=3 les plus proches: Chat, Chien, Renard → 2 domestiques, 1 sauvage

À vous de jouer! KNN

 **Exercice:** Animal domestique ou sauvage?

Animal	Taille (cm)	Poids (kg)	Type
Chat	30	4	Domestique 🏠
Chien	50	15	Domestique 🏠
Loup	80	35	Sauvage 🌲
Renard	60	7	Sauvage 🌲
?	40	8	?

Calculez avec K=3 et trouvez la classe!

💡 Réponse: Distances → Chat(10.2), Chien(11.4), Renard(20.1), Loup(50.9)

K=3 les plus proches: Chat, Chien, Renard → 2 domestiques, 1 sauvage

✅ **Domestique** 🏠



La Régression Logistique

Idée: Calculer la **probabilité** d'appartenir à une classe



La Régression Logistique

Idée: Calculer la **probabilité** d'appartenir à une classe



Contrairement à son nom, c'est pour la **classification**, pas la régression!

Elle donne: $P(\text{classe}=1)$ = probabilité entre 0 et 1



La Régression Logistique

Idée: Calculer la **probabilité** d'appartenir à une classe



Contrairement à son nom, c'est pour la **classification**, pas la régression!

Elle donne: $P(\text{classe}=1)$ = probabilité entre 0 et 1

$$P(y=1) = 1 / (1 + e^{(-z)})$$

$$\text{où } z = w_1x_1 + w_2x_2 + \dots + b$$



La Régression Logistique

Idée: Calculer la **probabilité** d'appartenir à une classe



Contrairement à son nom, c'est pour la **classification**, pas la régression!

Elle donne: $P(\text{classe}=1)$ = probabilité entre 0 et 1

$$P(y=1) = 1 / (1 + e^{(-z)})$$

$$\text{où } z = w_1x_1 + w_2x_2 + \dots + b$$

Exemple:

$P(\text{spam}) = 0.85 \rightarrow 85\%$ de chances que ce soit un spam ✓

$P(\text{spam}) = 0.15 \rightarrow 15\%$ de chances $\rightarrow$ C'est normal ✓




La fonction Sigmoid

La sigmoïde transforme n'importe quel nombre en probabilité (0 à 1)



La fonction Sigmoid


La sigmoïde transforme n'importe quel nombre en probabilité (0 à 1)





La fonction Sigmoid

La sigmoïde transforme n'importe quel nombre en probabilité (0 à 1)



💡 Interprétation:

- Si z très négatif ($z < -5$) → $P \approx 0$ (classe 0) 🔴
- Si $z \approx 0$ → $P \approx 0.5$ (incertain) 🟡
- Si z très positif ($z > 5$) → $P \approx 1$ (classe 1) 🟢



Régression Logistique - Calcul

Problème: Prédire si un email est un spam

Variables: Nb_mots_suspects (x_1), Nb_majuscules (x_2)



Régression Logistique - Calcul

Problème: Prédire si un email est un spam

Variables: Nb_mots_suspects (x_1), Nb_majuscules (x_2)

Modèle trouvé: $z = 2 \times x_1 + 1.5 \times x_2 - 3$



Régression Logistique - Calcul

Problème: Prédire si un email est un spam

Variables: Nb_mots_suspects (x_1), Nb_majuscules (x_2)

Modèle trouvé: $z = 2 \times x_1 + 1.5 \times x_2 - 3$

Email 1: 5 mots suspects, 10 majuscules

$$z = 2 \times 5 + 1.5 \times 10 - 3 = 10 + 15 - 3 = 22$$

$$P(\text{spam}) = 1 / (1 + e^{(-22)}) \approx \mathbf{0.9999999998} \approx 100\%$$



Régression Logistique - Calcul

Problème: Prédire si un email est un spam

Variables: Nb_mots_suspects (x_1), Nb_majuscules (x_2)

Modèle trouvé: $z = 2 \times x_1 + 1.5 \times x_2 - 3$

Email 1: 5 mots suspects, 10 majuscules

$$z = 2 \times 5 + 1.5 \times 10 - 3 = 10 + 15 - 3 = 22$$

$$P(\text{spam}) = 1 / (1 + e^{(-22)}) \approx \mathbf{0.9999999998} \approx 100\%$$

✅ **C'est un SPAM!**



Régression Logistique - Calcul

Problème: Prédire si un email est un spam

Variables: Nb_mots_suspects (x_1), Nb_majuscules (x_2)



Régression Logistique - Calcul

Problème: Prédire si un email est un spam

Variables: Nb_mots_suspects (x_1), Nb_majuscules (x_2)

Modèle trouvé: $z = 2 \times x_1 + 1.5 \times x_2 - 3$



Régression Logistique - Calcul

Problème: Prédire si un email est un spam

Variables: Nb_mots_suspects (x_1), Nb_majuscules (x_2)

Modèle trouvé: $z = 2 \times x_1 + 1.5 \times x_2 - 3$

Email 2: 0 mots suspects, 2 majuscules

$$z = 2 \times 0 + 1.5 \times 2 - 3 = 0 + 3 - 3 = 0$$

$$P(\text{spam}) = 1 / (1 + e^0) = 1/2 = \mathbf{0.5} = 50\%$$



Régression Logistique - Calcul

Problème: Prédire si un email est un spam

Variables: Nb_mots_suspects (x_1), Nb_majuscules (x_2)

Modèle trouvé: $z = 2 \times x_1 + 1.5 \times x_2 - 3$

Email 2: 0 mots suspects, 2 majuscules

$$z = 2 \times 0 + 1.5 \times 2 - 3 = 0 + 3 - 3 = 0$$

$$P(\text{spam}) = 1 / (1 + e^0) = 1/2 = \mathbf{0.5} = 50\%$$

⚠ **Incertain!** (seuil souvent à 0.5)



Les Arbres de Décision

Idée: Poser une série de **questions** pour arriver à la décision



Les Arbres de Décision

Idée: Poser une série de **questions** pour arriver à la décision



Exemple: Jouer au tennis aujourd'hui?




Les Arbres de Décision

Idée: Poser une série de **questions** pour arriver à la décision



Exemple: Jouer au tennis aujourd'hui?






Les Arbres de Décision

Idée: Poser une série de **questions** pour arriver à la décision



Exemple: Jouer au tennis aujourd'hui?



Avantages: Facile à comprendre et interpréter!



Chaque branche = une règle de décision




Arbre de Décision - Exemple Fruits

Classifier: Pomme 🍏 vs Orange 🍊 vs Banane 🍌



Arbre de Décision - Exemple Fruits


Classifier: Pomme 🍏 vs Orange 🍊 vs Banane 🍌





Arbre de Décision - Exemple Fruits

Classifier: Pomme 🍏 vs Orange 🍊 vs Banane 🍌




🎯 **Nouveau fruit:** Couleur=20, Forme=ronde



Arbre de Décision - Exemple Fruits

Classifier: Pomme 🍏 vs Orange 🍊 vs Banane 🍌




🎯 **Nouveau fruit:** Couleur=20, Forme=ronde

Q1: Couleur < 50? → Oui (va à gauche)



Arbre de Décision - Exemple Fruits

Classifier: Pomme 🍏 vs Orange 🍊 vs Banane 🍌



🎯 **Nouveau fruit:** Couleur=20, Forme=ronde


Q1: Couleur < 50? → Oui (va à gauche)

Q2: Forme ronde? → Oui (va à gauche)



Arbre de Décision - Exemple Fruits

Classifier: Pomme 🍏 vs Orange 🍊 vs Banane 🍌



🎯 **Nouveau fruit:** Couleur=20, Forme=ronde

Q1: Couleur < 50? → Oui (va à gauche)

Q2: Forme ronde? → Oui (va à gauche)

✅ **Résultat: POMME 🍏**

À vous! Arbre de Décision

 Créez un arbre pour: Acheter un jeu vidéo?

Prix	Note /10	Multijoueur	Acheter?
€20	9	Oui	Oui 
€60	5	Oui	Non 
€30	8	Non	Oui 
€70	9	Oui	Non 

À vous! Arbre de Décision

 Créez un arbre pour: Acheter un jeu vidéo?

Prix	Note /10	Multijoueur	Acheter?
€20	9	Oui	Oui 
€60	5	Oui	Non 
€30	8	Non	Oui 
€70	9	Oui	Non 

 Règle observée:

À vous! Arbre de Décision

 Créez un arbre pour: Acheter un jeu vidéo?

Prix	Note /10	Multijoueur	Acheter?
€20	9	Oui	Oui ✓
€60	5	Oui	Non ✗
€30	8	Non	Oui ✓
€70	9	Oui	Non ✗

 Règle observée:

Si Prix > €50 → Non ✗

À vous! Arbre de Décision

 Créez un arbre pour: Acheter un jeu vidéo?

Prix	Note /10	Multijoueur	Acheter?
€20	9	Oui	Oui ✓
€60	5	Oui	Non ✗
€30	8	Non	Oui ✓
€70	9	Oui	Non ✗

 Règle observée:

Si Prix > €50 → Non ✗

Sinon, si Note $\geq$ 8 → Oui ✓

À vous! Arbre de Décision

 Créez un arbre pour: Acheter un jeu vidéo?

Prix	Note /10	Multijoueur	Acheter?
€20	9	Oui	Oui ✓
€60	5	Oui	Non ✗
€30	8	Non	Oui ✓
€70	9	Oui	Non ✗

 Règle observée:

Si Prix > €50 → Non ✗

Sinon, si Note $\geq$ 8 → Oui ✓

Sinon → Non ✗



Quel algorithme choisir?

Algorithme	Avantages	Inconvénients	Quand l'utiliser?
KNN	Très simple Pas d'entraînement	Lent sur gros datasets Sensible à l'échelle	Petits datasets Peu de features
Régression Logistique	Rapide Donne probabilités	Seulement linéaire	Relations linéaires Interprétabilité
Arbres de Décision	Facile à interpréter Non-linéaire	Sur-ajustement Instables	Règles métier Données mixtes



Comment mesurer la performance?

Matrice de Confusion - Le tableau de bord



Comment mesurer la performance?

Matrice de Confusion - Le tableau de bord

		Prédiction	
		Positif	Négatif
Réal	Positif	VP Vrai Positif	FN Faux Négatif
	Négatif	FP Faux Positif	VN Vrai Négatif



Comment mesurer la performance?

Matrice de Confusion - Le tableau de bord

		Prédiction	
		Positif	Négatif
Réal	Positif	VP Vrai Positif	FN Faux Négatif
	Négatif	FP Faux Positif	VN Vrai Négatif

VP: On dit chat, c'était un chat ✓

VN: On dit chien, c'était un chien ✓

FP: On dit chat, mais c'était un chien ✗

FN: On dit chien, mais c'était un chat ✗



Les métriques importantes

Accuracy (Exactitude) = $(VP + VN) / Total$

% de prédictions correctes



Les métriques importantes

Accuracy (Exactitude) = $(VP + VN) / Total$

% de prédictions correctes

Precision (Précision) = $VP / (VP + FP)$

Quand je dis "positif", à quelle fréquence j'ai raison?



Les métriques importantes

$$\text{Accuracy (Exactitude)} = (\text{VP} + \text{VN}) / \text{Total}$$

% de prédictions correctes

$$\text{Precision (Précision)} = \text{VP} / (\text{VP} + \text{FP})$$

Quand je dis "positif", à quelle fréquence j'ai raison?

$$\text{Recall (Rappel)} = \text{VP} / (\text{VP} + \text{FN})$$

Des vrais positifs, combien ai-je trouvé?



Les métriques importantes

$$\text{Accuracy (Exactitude)} = (\text{VP} + \text{VN}) / \text{Total}$$

% de prédictions correctes

$$\text{Precision (Précision)} = \text{VP} / (\text{VP} + \text{FP})$$

Quand je dis "positif", à quelle fréquence j'ai raison?

$$\text{Recall (Rappel)} = \text{VP} / (\text{VP} + \text{FN})$$

Des vrais positifs, combien ai-je trouvé?

$$\text{F1-Score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Équilibre entre Precision et Recall



Calcul des Métriques - Exemple

Détection de spam: 100 emails testés



Calcul des Métriques - Exemple

Détection de spam: 100 emails testés

	Prédit Spam	Prédit Normal
Vrai Spam	40 (VP)	10 (FN)
Vrai Normal	5 (FP)	45 (VN)



Calcul des Métriques - Exemple

Détection de spam: 100 emails testés

	Prédit Spam	Prédit Normal
Vrai Spam	40 (VP)	10 (FN)
Vrai Normal	5 (FP)	45 (VN)

$$\text{Accuracy} = (40+45)/100 = 85\% \checkmark$$

$$\text{Precision} = 40/(40+5) = 88.9\% \text{ (spam détecté = souvent vrai)}$$

$$\text{Recall} = 40/(40+10) = 80\% \text{ (80\% des spams trouvés)}$$

$$\text{F1-Score} = 2 \times (0.889 \times 0.8) / (0.889 + 0.8) = 84.2\%$$



Code Python - KNN

```
# Importer les bibliothèques
from sklearn.neighbors import KNeighborsClassifier
import numpy as np

# Données d'entraînement (fruits)
X_train = np.array([
    [150, 7, 10],    # Pomme
    [170, 7.5, 15],  # Pomme
    [140, 8, 85],    # Orange
    [130, 7.5, 90]   # Orange
])
y_train = np.array(['Pomme', 'Pomme', 'Orange', 'Orange'])

# Créer le modèle KNN avec K=3
knn = KNeighborsClassifier(n_neighbors=3)
knn.fit(X_train, y_train)

# Prédire un nouveau fruit
nouveau_fruit = np.array([[145, 7.2, 12]])
prediction = knn.predict(nouveau_fruit)
```



Code Python - Régression Logistique

```
# Régression Logistique pour spam
from sklearn.linear_model import LogisticRegression

# Données: [mots_suspects, majuscules]
X_train = np.array([
    [0, 2], # Normal
    [1, 5], # Normal
    [5, 10], # Spam
    [7, 15] # Spam
])
y_train = np.array([0, 0, 1, 1]) # 0=Normal, 1=Spam

# Créer et entraîner
model = LogisticRegression()
model.fit(X_train, y_train)

# Prédire
email_test = np.array([[3, 8]])
prediction = model.predict(email_test)
probabilite = model.predict_proba(email_test)
```



Code Python - Arbre de Décision

```
# Arbre de Décision
from sklearn.tree import DecisionTreeClassifier
from sklearn import tree
import matplotlib.pyplot as plt


# Données
X_train = np.array([[20, 9], [60, 5], [30, 8], [70, 9]])
y_train = np.array(['Acheter', 'Pas acheter', 'Acheter', 'Pas acheter'])

# Créer l'arbre
clf = DecisionTreeClassifier(max_depth=3)
clf.fit(X_train, y_train)

# Visualiser l'arbre
plt.figure(figsize=(12,8))
tree.plot_tree(clf, feature_names=['Prix', 'Note'],
               class_names=['Acheter', 'Pas acheter'],
               filled=True)
plt.show()
```



Points clés à retenir





Points clés à retenir

1. 🎯 Classification = prédire une **catégorie**



Points clés à retenir

1. 🎯 Classification = prédire une **catégorie**
2. 👤 KNN = Vote des voisins (simple et intuitif)



Points clés à retenir

1. 🎯 Classification = prédire une **catégorie**
2. 👤 KNN = Vote des voisins (simple et intuitif)
3. 📈 Régression Logistique = Probabilités (0 à 1)



Points clés à retenir

1. 🎯 Classification = prédire une **catégorie**
2. 👤 KNN = Vote des voisins (simple et intuitif)
3. 📈 Régression Logistique = Probabilités (0 à 1)
4. 🌳 Arbres = Série de questions/règles



Points clés à retenir

1. 🎯 Classification = prédire une **catégorie**
2. 👤 KNN = Vote des voisins (simple et intuitif)
3. 📈 Régression Logistique = Probabilités (0 à 1)
4. 🌳 Arbres = Série de questions/règles
5. 📊 Toujours évaluer avec matrice de confusion



Points clés à retenir

1. 🎯 Classification = prédire une **catégorie**
2. 👤 KNN = Vote des voisins (simple et intuitif)
3. 📈 Régression Logistique = Probabilités (0 à 1)
4. 🌳 Arbres = Série de questions/règles
5. 📊 Toujours évaluer avec matrice de confusion
6. ⚖️ Choisir selon le problème et les données



Points clés à retenir

1. 🎯 Classification = prédire une **catégorie**
2. 👤 KNN = Vote des voisins (simple et intuitif)
3. 📈 Régression Logistique = Probabilités (0 à 1)
4. 🌳 Arbres = Série de questions/règles
5. 📊 Toujours évaluer avec matrice de confusion
6. ⚖️ Choisir selon le problème et les données
7. 🧪 Tester sur données séparées!

Pièges à éviter

Classes déséquilibrées

99% classe A, 1% classe B → 99% accuracy facile mais inutile!

Pièges à éviter

Classes déséquilibrées

99% classe A, 1% classe B → 99% accuracy facile mais inutile!

→ Utiliser F1-Score, pas seulement Accuracy

Pièges à éviter

Classes déséquilibrées

99% classe A, 1% classe B → 99% accuracy facile mais inutile!

→ Utiliser F1-Score, pas seulement Accuracy

Sur-ajustement

Arbre trop profond = parfait sur train, mauvais sur test

Pièges à éviter

Classes déséquilibrées

99% classe A, 1% classe B → 99% accuracy facile mais inutile!

→ Utiliser F1-Score, pas seulement Accuracy

Sur-ajustement

Arbre trop profond = parfait sur train, mauvais sur test

→ Limiter la profondeur, utiliser validation croisée

Pièges à éviter

Classes déséquilibrées

99% classe A, 1% classe B → 99% accuracy facile mais inutile!

→ Utiliser F1-Score, pas seulement Accuracy

Sur-ajustement

Arbre trop profond = parfait sur train, mauvais sur test

→ Limiter la profondeur, utiliser validation croisée

Oublier la normalisation (KNN)

Feature 1: [0-1], Feature 2: [0-1000] → Distance biaisée!

Pièges à éviter

Classes déséquilibrées

99% classe A, 1% classe B → 99% accuracy facile mais inutile!

→ Utiliser F1-Score, pas seulement Accuracy

Sur-ajustement

Arbre trop profond = parfait sur train, mauvais sur test

→ Limiter la profondeur, utiliser validation croisée

Oublier la normalisation (KNN)

Feature 1: [0-1], Feature 2: [0-1000] → Distance biaisée!

→ Toujours normaliser pour KNN

Projet Final - Système de Recommandation

Mission: Prédire si un client va aimer un film



Projet Final - Système de Recommandation

Mission: Prédire si un client va aimer un film

Données disponibles:

- Âge du client
- Genre préféré (action, romance, comédie)
- Note moyenne donnée
- Nombre de films vus



Projet Final - Système de Recommandation

Mission: Prédire si un client va aimer un film

Données disponibles:

- Âge du client
- Genre préféré (action, romance, comédie)
- Note moyenne donnée
- Nombre de films vus

Étapes à suivre:

1. Nettoyer et préparer les données
2. Tester KNN, Régression Logistique, Arbre
3. Comparer les performances (matrice de confusion)
4. Choisir le meilleur modèle
5. Faire des prédictions!



Conclusion

"La classification, c'est comme apprendre à un ordinateur à reconnaître des motifs, comme nous le faisons naturellement!"



Conclusion

"La classification, c'est comme apprendre à un ordinateur à reconnaître des motifs, comme nous le faisons naturellement!"

Vous savez maintenant:

-  Comprendre la classification
-  Appliquer KNN, Régression Logistique, Arbres
-  Calculer distances et probabilités
-  Évaluer avec métriques appropriées
-  Coder en Python avec scikit-learn



Conclusion

"La classification, c'est comme apprendre à un ordinateur à reconnaître des motifs, comme nous le faisons naturellement!"

Vous savez maintenant:

-  Comprendre la classification
-  Appliquer KNN, Régression Logistique, Arbres
-  Calculer distances et probabilités
-  Évaluer avec métriques appropriées
-  Coder en Python avec scikit-learn



Prêts à classifier le monde!

Questions?

Joseph Azar

joseph.azar@univ-fcomte.fr

Université Marie Louis Pasteur



Prochaine session: Clustering - Découvrir des groupes cachés!



Préparez-vous pour encore plus d'interactions!