


Le Clustering

Découvrir des groupes cachés dans les données

Joseph Azar

Maître de conférences
Université Marie Louis Pasteur
Intelligence Artificielle - Semaine 5

Une fête avec des inconnus...



Une fête avec des inconnus...

Vous entrez dans une salle avec 100 personnes que vous ne connaissez pas 🎉

Une fête avec des inconnus...

Vous entrez dans une salle avec 100 personnes que vous ne connaissez pas 🎉

Vous commencez à observer et remarquez des groupes naturels:

Une fête avec des inconnus...

Vous entrez dans une salle avec 100 personnes que vous ne connaissez pas 🎉

Vous commencez à observer et remarquez des groupes naturels:

-  Un groupe de personnes en costume (professionnels)
-  Un groupe en t-shirts et jeans (étudiants)
-  Un groupe élégant (invités VIP)

Une fête avec des inconnus...

Vous entrez dans une salle avec 100 personnes que vous ne connaissez pas 🎉

Vous commencez à observer et remarquez des groupes naturels:

-  Un groupe de personnes en costume (professionnels)
-  Un groupe en t-shirts et jeans (étudiants)
-  Un groupe élégant (invités VIP)

Vous venez de faire du clustering dans votre tête! 🧠

Une fête avec des inconnus...

Vous entrez dans une salle avec 100 personnes que vous ne connaissez pas 🎉

Vous commencez à observer et remarquez des groupes naturels:

-  Un groupe de personnes en costume (professionnels)
-  Un groupe en t-shirts et jeans (étudiants)
-  Un groupe élégant (invités VIP)

Vous venez de faire du clustering dans votre tête! 🧠

💡 Le clustering = **trouver des groupes naturels** dans les données, **sans étiquettes préalables!**

Qu'est-ce que le Clustering?

Définition: Le clustering (regroupement) est une technique d'apprentissage **non supervisé** qui regroupe des données similaires ensemble

Qu'est-ce que le Clustering?

Définition: Le clustering (regroupement) est une technique d'apprentissage **non supervisé** qui regroupe des données similaires ensemble

Objectif

Découvrir des **structures cachées**

Pas de labels → L'algorithme découvre les groupes

≠ Classification

Classification: On connaît les catégories (supervisé)

Clustering: On découvre les groupes (non supervisé)

Plan de la présentation

Plan de la présentation

1. 🤔 Qu'est-ce que le clustering?

Plan de la présentation

1. 🤔 Qu'est-ce que le clustering?
2. 🌐 Applications concrètes

Plan de la présentation

1. 🤔 Qu'est-ce que le clustering?
2. 🌐 Applications concrètes
3. 📊 K-Means - L'algorithme star

Plan de la présentation

1. 🤔 Qu'est-ce que le clustering?
2. 🌐 Applications concrètes
3. 📊 K-Means - L'algorithme star
4. ♟️ Calcul manuel étape par étape

Plan de la présentation

1. 🤔 Qu'est-ce que le clustering?
2. 🌐 Applications concrètes
3. 📊 K-Means - L'algorithme star
4. ♟️ Calcul manuel étape par étape
5. 🔗 Clustering Hiérarchique

Plan de la présentation

1. 🤔 Qu'est-ce que le clustering?
2. 🌐 Applications concrètes
3. 📊 K-Means - L'algorithme star
4. ♟️ Calcul manuel étape par étape
5. 🔗 Clustering Hiérarchique
6. 🎯 DBSCAN - Densité

Plan de la présentation

1. 🤔 Qu'est-ce que le clustering?
2. 🌐 Applications concrètes
3. 📊 K-Means - L'algorithme star
4. ♟️ Calcul manuel étape par étape
5. 🔗 Clustering Hiérarchique
6. 🎯 DBSCAN - Densité
7. 📐 Comment choisir K?

Plan de la présentation

1. 🤔 Qu'est-ce que le clustering?
2. 🌐 Applications concrètes
3. 📊 K-Means - L'algorithme star
4. ♟️ Calcul manuel étape par étape
5. 🔗 Clustering Hiérarchique
6. 🎯 DBSCAN - Densité
7. 📏 Comment choisir K?
8. ⚖️ Évaluer la qualité

Applications dans la vie réelle

Marketing

- Segmentation clients
- Profils d'acheteurs
- Recommandations personnalisées

Tech

- Organisation de documents
- Compression d'images
- Détection d'anomalies

Biologie & Santé

- Classification de gènes
- Groupes de patients
- Analyse de symptômes

Réseaux Sociaux


- Communautés d'utilisateurs
- Sujets tendances
- Groupes d'intérêts

👁️ Le problème visuellement

Avant le clustering: Des points dispersés


👁️ Le problème visuellement

Avant le clustering: Des points dispersés



👁️ Le problème visuellement


Avant le clustering: Des points dispersés




Après le clustering: Groupes identifiés!

👁️ Le problème visuellement

Avant le clustering: Des points dispersés



Après le clustering: Groupes identifiés!





K-Means - L'algorithme le plus populaire

Idée: Créer K groupes en minimisant la distance entre les points et leur centre



K-Means - L'algorithme le plus populaire

Idée: Créer K groupes en minimisant la distance entre les points et leur centre

Algorithme en 4 étapes:

1. **Initialisation:** Choisir K centres aléatoires (centroids)
2. **Assignment:** Assigner chaque point au centre le plus proche
3. **Mise à jour:** Recalculer les centres (moyenne des points)
4. **Répéter:** Étapes 2-3 jusqu'à convergence



K-Means - L'algorithme le plus populaire

Idée: Créer K groupes en minimisant la distance entre les points et leur centre

Algorithme en 4 étapes:

1. **Initialisation:** Choisir K centres aléatoires (centroids)
2. **Assignment:** Assigner chaque point au centre le plus proche
3. **Mise à jour:** Recalculer les centres (moyenne des points)
4. **Répéter:** Étapes 2-3 jusqu'à convergence


💡 "K" = nombre de clusters souhaités (à choisir!)



K-Means - Calculons ensemble! (1/5)



Objectif: Grouper ces clients en K=2 clusters






K-Means - Calculons ensemble! (1/5)



Objectif: Grouper ces clients en K=2 clusters




Étape 1: Initialisation (choix aléatoire)

Centre 1 (C1) = Point A (25, 30) ● | Centre 2 (C2) = Point D (50, 75) ●



K-Means - Calculons ensemble! (2/5)


Étape 2: Calculer distances et assigner





K-Means - Calculons ensemble! (2/5)

Étape 2: Calculer distances et assigner




Client B (30, 35): $d(C1)=7.07$, $d(C2)=44.72 \rightarrow C1$ 

Client C (45, 70): $d(C1)=44.72$, $d(C2)=7.07 \rightarrow C2$ 



K-Means - Calculons ensemble! (3/5)


Résultat après toutes les assignments:





K-Means - Calculons ensemble! (3/5)

Résultat après toutes les assignments:




Cluster 1 ●: A, B, E (jeunes, revenus modestes)



K-Means - Calculons ensemble! (4/5)


Étape 3: Recalculer les centres (moyenne)





K-Means - Calculons ensemble! (4/5)

Étape 3: Recalculer les centres (moyenne)




Nouveau C1: $X = (25+30+28)/3 = 27.67$, $Y = (30+35+32)/3 = 32.33 \rightarrow (27.67, 32.33)$

Nouveau C2: $X = (45+50)/2 = 47.5$, $Y = (70+75)/2 = 72.5 \rightarrow (47.5, 72.5)$



K-Means - Calculons ensemble! (4/5)

Étape 3: Recalculer les centres (moyenne)



Nouveau C1: $X = (25+30+28)/3 = 27.67$, $Y = (30+35+32)/3 = 32.33 \rightarrow (27.67, 32.33)$


Nouveau C2: $X = (45+50)/2 = 47.5$, $Y = (70+75)/2 = 72.5 \rightarrow (47.5, 72.5)$

💡 Les centres se sont déplacés vers le milieu de leurs clusters!



K-Means - Calculons ensemble! (5/5)


Étape 4: Vérifier la convergence





K-Means - Calculons ensemble! (5/5)

Étape 4: Vérifier la convergence




Les assignations ne changent pas? ✓ **Convergence!**



K-Means - Calculons ensemble! (5/5)

Étape 4: Vérifier la convergence



Les assignations ne changent pas? ✓ **Convergence!**

Résultat final:

Cluster 1: Jeunes professionnels

Cluster 2: Cadres expérimentés

À vous de jouer! K-Means

 **Exercice:** K=2 clusters pour ces villes

Ville	Température (°C)	Précipitations (mm)
Paris	12	600
Nice	16	700
Marseille	15	500
Lille	11	700

À vous de jouer! K-Means

 **Exercice:** K=2 clusters pour ces villes

Ville	Température (°C)	Précipitations (mm)
Paris	12	600
Nice	16	700
Marseille	15	500
Lille	11	700



Prenez votre papier et crayon!

Centres initiaux: C1 = Paris (12, 600), C2 = Marseille (15, 500)



Exercice K-Means - Étape 1

Calculer les distances pour Nice (16, 700)



Exercice K-Means - Étape 1

Calculer les distances pour Nice (16, 700)

Distance à C1 Paris (12, 600) :



Exercice K-Means - Étape 1

Calculer les distances pour Nice (16, 700)

Distance à C1 Paris (12, 600) :

$$d = \sqrt{(16-12)^2 + (700-600)^2} = \sqrt{16 + 10000} = 100.08$$



Exercice K-Means - Étape 1

Calculer les distances pour Nice (16, 700)

Distance à C1 Paris (12, 600) :

$$d = \sqrt{(16-12)^2 + (700-600)^2} = \sqrt{16 + 10000} = 100.08$$

Distance à C2 Marseille (15, 500) :



Exercice K-Means - Étape 1

Calculer les distances pour Nice (16, 700)

Distance à C1 Paris (12, 600) :

$$d = \sqrt{(16-12)^2 + (700-600)^2} = \sqrt{16 + 10000} = 100.08$$

Distance à C2 Marseille (15, 500) :

$$d = \sqrt{(16-15)^2 + (700-500)^2} = \sqrt{1 + 40000} = 200.00$$



Exercice K-Means - Étape 1

Calculer les distances pour Nice (16, 700)

Distance à C1 Paris (12, 600) :

$$d = \sqrt{(16-12)^2 + (700-600)^2} = \sqrt{16 + 10000} = 100.08$$

Distance à C2 Marseille (15, 500) :

$$d = \sqrt{(16-15)^2 + (700-500)^2} = \sqrt{1 + 40000} = 200.00$$

→ Nice est plus proche de C1 (Paris) ●



Exercice K-Means - Étape 2

Calculer les distances pour Lille (11, 700)



Exercice K-Means - Étape 2

Calculer les distances pour Lille (11, 700)

Distance à C1 Paris (12, 600) :



Exercice K-Means - Étape 2

Calculer les distances pour Lille (11, 700)

Distance à C1 Paris (12, 600) :

$$d = \sqrt{(11-12)^2 + (700-600)^2} = \sqrt{1 + 10000} = 100.00$$



Exercice K-Means - Étape 2

Calculer les distances pour Lille (11, 700)

Distance à C1 Paris (12, 600) :

$$d = \sqrt{[(11-12)^2 + (700-600)^2]} = \sqrt{[1 + 10000]} = 100.00$$

Distance à C2 Marseille (15, 500) :



Exercice K-Means - Étape 2

Calculer les distances pour Lille (11, 700)

Distance à C1 Paris (12, 600) :

$$d = \sqrt{[(11-12)^2 + (700-600)^2]} = \sqrt{[1 + 10000]} = 100.00$$

Distance à C2 Marseille (15, 500) :

$$d = \sqrt{[(11-15)^2 + (700-500)^2]} = \sqrt{[16 + 40000]} = 200.04$$



Exercice K-Means - Étape 2

Calculer les distances pour Lille (11, 700)

Distance à C1 Paris (12, 600) :

$$d = \sqrt{[(11-12)^2 + (700-600)^2]} = \sqrt{[1 + 10000]} = 100.00$$

Distance à C2 Marseille (15, 500) :

$$d = \sqrt{[(11-15)^2 + (700-500)^2]} = \sqrt{[16 + 40000]} = 200.04$$

→ Lille est plus proche de C1 (Paris) ●

Exercice K-Means - Étape 3

Assignation des clusters

Ville	Position	Cluster
Paris	(12, 600)	 Cluster 1 (initial)
Marseille	(15, 500)	 Cluster 2 (initial)

Exercice K-Means - Étape 3

Assignment des clusters

Ville	Position	Cluster
Paris	(12, 600)	 Cluster 1 (initial)
Nice	(16, 700)	 Cluster 1
Marseille	(15, 500)	 Cluster 2 (initial)

Exercice K-Means - Étape 3

Assignment des clusters

Ville	Position	Cluster
Paris	(12, 600)	 Cluster 1 (initial)
Nice	(16, 700)	 Cluster 1
Lille	(11, 700)	 Cluster 1
Marseille	(15, 500)	 Cluster 2 (initial)

Exercice K-Means - Étape 3

Assignation des clusters

Ville	Position	Cluster
Paris	(12, 600)	 Cluster 1 (initial)
Nice	(16, 700)	 Cluster 1
Lille	(11, 700)	 Cluster 1
Marseille	(15, 500)	 Cluster 2 (initial)

⚠ Tous les points vont vers Cluster 1 sauf Marseille!

Il faut recalculer les centres...



Exercice K-Means - Étape 4

Recalculer les nouveaux centres



Exercice K-Means - Étape 4

Recalculer les nouveaux centres

Nouveau C1 (Paris, Nice, Lille):



Exercice K-Means - Étape 4

Recalculer les nouveaux centres

Nouveau C1 (Paris, Nice, Lille):

$$X = (12+16+11)/3 = 39/3 = \mathbf{13} \mid Y = (600+700+700)/3 = 2000/3 = \mathbf{666.67}$$



Exercice K-Means - Étape 4

Recalculer les nouveaux centres

Nouveau C1 (Paris, Nice, Lille):

$$X = (12+16+11)/3 = 39/3 = \mathbf{13} \mid Y = (600+700+700)/3 = 2000/3 = \mathbf{666.67}$$

→ Nouveau C1 = **(13, 666.67)**



Exercice K-Means - Étape 4

Recalculer les nouveaux centres

Nouveau C1 (Paris, Nice, Lille):

$$X = (12+16+11)/3 = 39/3 = \mathbf{13} \mid Y = (600+700+700)/3 = 2000/3 = \mathbf{666.67}$$

→ Nouveau C1 = **(13, 666.67)**

Nouveau C2 (Marseille seulement):



Exercice K-Means - Étape 4

Recalculer les nouveaux centres

Nouveau C1 (Paris, Nice, Lille):

$$X = (12+16+11)/3 = 39/3 = \mathbf{13} \mid Y = (600+700+700)/3 = 2000/3 = \mathbf{666.67}$$

→ Nouveau C1 = **(13, 666.67)**

Nouveau C2 (Marseille seulement):

$$X = 15, Y = 500 \rightarrow \text{Nouveau C2} = \mathbf{(15, 500)} \text{ (inchangé)}$$



Exercice K-Means - Étape 4

Recalculer les nouveaux centres

Nouveau C1 (Paris, Nice, Lille):

$$X = (12+16+11)/3 = 39/3 = \mathbf{13} \mid Y = (600+700+700)/3 = 2000/3 = \mathbf{666.67}$$
$$\rightarrow \text{Nouveau C1} = \mathbf{(13, 666.67)}$$

Nouveau C2 (Marseille seulement):

$$X = 15, Y = 500 \rightarrow \text{Nouveau C2} = \mathbf{(15, 500)} \text{ (inchangé)}$$



C1 s'est déplacé vers le nord pluvieux!



Exercice K-Means - Convergence

Vérifier: Faut-il continuer?



Exercice K-Means - Convergence

Vérifier: Faut-il continuer?

Avec les nouveaux centres C1(13, 666.67) et C2(15, 500):

→ Recalculer distances | Si aucun changement:  **Convergence!** | Si changement:  Retour assignation



Exercice K-Means - Convergence

Vérifier: Faut-il continuer?

Avec les nouveaux centres C1(13, 666.67) et C2(15, 500):

→ Recalculer distances | Si aucun changement: **Convergence!** | Si changement: Retour assignation

Résultat probable:

Cluster 1: Paris, Nice, Lille (Nord, pluvieux) | Cluster 2: Marseille (Sud, sec)



Exercice K-Means - Convergence

Vérifier: Faut-il continuer?

Avec les nouveaux centres C1(13, 666.67) et C2(15, 500):

→ Recalculer distances | Si aucun changement: **Convergence!** | Si changement: Retour assignation

Résultat probable:

Cluster 1: Paris, Nice, Lille (Nord, pluvieux) | Cluster 2: Marseille (Sud, sec)

Réflexion: Nice devrait-elle être avec Paris et Lille? → Limite de K-Means avec K=2!



Clustering Hiérarchique

Idée: Construire une **hiérarchie** de clusters (arbre/dendrogramme)



Clustering Hiérarchique

Idée: Construire une **hiérarchie** de clusters (arbre/dendrogramme)

Approche Agglomérative

1. Chaque point = 1 cluster
2. Fusionner les 2 plus proches
3. Répéter jusqu'à 1 cluster

Approche Divisive

1. Tous les points = 1 cluster
2. Diviser en 2 sous-clusters
3. Répéter récursivement



Clustering Hiérarchique

Idée: Construire une **hiérarchie** de clusters (arbre/dendrogramme)

Approche Agglomérative

1. Chaque point = 1 cluster
2. Fusionner les 2 plus proches
3. Répéter jusqu'à 1 cluster

Approche Divisive

1. Tous les points = 1 cluster
2. Diviser en 2 sous-clusters
3. Répéter récursivement


 **Avantage:** Pas besoin de choisir K à l'avance!

 On "coupe" le dendrogramme au niveau souhaité




Le Dendrogramme - Exemple Réel

Clustering Hiérarchique - Dendrogramme





Le Dendrogramme - Exemple Réel




Comment lire:

- Couper au seuil rouge (hauteur 50) → 2 clusters: {A,B,C} et {D,E,F}
- Plus la fusion est haute, plus les groupes sont différents



Clustering Hiérarchique - Étapes


Clustering Hiérarchique - Étapes Agglomératives





Clustering Hiérarchique - Étapes

Clustering Hiérarchique - Étapes Agglomératives



✓ **Avantage:** On voit la progression de fusion des clusters à chaque étape!



DBSCAN - Clustering par Densité

Idée: Les clusters = zones **denses** de points, séparées par zones peu denses



DBSCAN - Clustering par Densité

Idée: Les clusters = zones **denses** de points, séparées par zones peu denses

Paramètres:

- **ϵ (epsilon):** Rayon de voisinage
- **MinPts:** Nombre minimum de points pour former un cluster



DBSCAN - Clustering par Densité

Idée: Les clusters = zones **denses** de points, séparées par zones peu denses

Paramètres:


- **ϵ (epsilon):** Rayon de voisinage
- **MinPts:** Nombre minimum de points pour former un cluster

Types de points:

- **Core point (noyau):** $\geq$ MinPts voisins dans rayon ϵ
- **Border point (frontière):** Voisin d'un core point mais pas core
- **Noise (bruit):** Ni core ni border $\rightarrow$ Outlier!




DBSCAN - Exemple Réel






DBSCAN - Exemple Réel



✓ DBSCAN détecte automatiquement les formes arbitraires et identifie les points de bruit!


DBSCAN - Impact des Paramètres

DBSCAN - Impact des Paramètres eps et min_samples



DBSCAN - Impact des Paramètres

DBSCAN - Impact des Paramètres eps et min_samples



⚠ **Important:** eps trop petit → trop de bruit | eps trop grand → tout devient un cluster



Quelle méthode choisir?

Méthode	Avantages	Inconvénients	Quand l'utiliser?
K-Means	Rapide Simple Scalable	Besoin de K Clusters sphériques	Clusters bien séparés Taille connue
Hiérarchique	Pas de K Dendrogramme Flexible	Lent Grande mémoire	Hiérarchie importante Petits datasets
DBSCAN	Formes arbitraires Déetecte bruit Pas de K	Paramètres ϵ , MinPts Densité variable	Formes complexes Outliers importants




Comment choisir K? (Méthode du Coude)


Inertie: Somme des distances au carré de chaque point à son centre

□ Méthode du Coude - Comment Choisir K Optimal?

Données à Clustériser



□ Méthode du Coude (Elbow Method)






Comment choisir K? (Méthode du Coude)

Inertie: Somme des distances au carré de chaque point à son centre

Méthode du Coude (Elbow Method):

1. Tester $K=1,2,3\dots 10$ → 2. Calculer inertie → 3. Tracer graphique → 4. Chercher "coude"






Comment choisir K? (Méthode du Coude)

Inertie: Somme des distances au carré de chaque point à son centre

Méthode du Coude (Elbow Method):


1. Tester K=1,2,3...10 → 2. Calculer inertie → 3. Tracer graphique → 4. Chercher "coude"



📌 Le "coude" indique le K optimal → Après, ajouter des clusters n'améliore plus beaucoup!


🔍 Comparaison: K=2 vs K=3 vs K=4

□ Comparaison: Impact du Choix de K



Comparaison: K=2 vs K=3 vs K=4

□ Comparaison: Impact du Choix de K



✓ K=3 est optimal: meilleur compromis entre inertie faible et nombre de clusters raisonnable

Évaluer la qualité du clustering

Silhouette Score

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

$a(i)$ = distance moyenne au même cluster

$b(i)$ = distance moyenne au cluster le plus proche

Évaluer la qualité du clustering

Silhouette Score

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

$a(i)$ = distance moyenne au même cluster

$b(i)$ = distance moyenne au cluster le plus proche

Interprétation:

- s proche de +1 → Bon clustering 
- s proche de 0 → Clusters se chevauchent 
- s proche de -1 → Mauvais clustering 

Évaluer la qualité du clustering

Silhouette Score

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

$a(i)$ = distance moyenne au même cluster

$b(i)$ = distance moyenne au cluster le plus proche

Interprétation:

- s proche de +1 → Bon clustering 
- s proche de 0 → Clusters se chevauchent 
- s proche de -1 → Mauvais clustering 

Autres métriques:

- **Davies-Bouldin Index:** Plus bas = mieux
- **Calinski-Harabasz:** Plus haut = mieux



Calcul Silhouette - Exemple

Point A du Cluster 1:



Calcul Silhouette - Exemple

Point A du Cluster 1:

a(A): Distance moyenne aux autres points du Cluster 1

Points du Cluster 1: A, B, C

$$a(A) = [\text{dist}(A,B) + \text{dist}(A,C)] / 2 = (2 + 3) / 2 = \mathbf{2.5}$$



Calcul Silhouette - Exemple

Point A du Cluster 1:

a(A): Distance moyenne aux autres points du Cluster 1

Points du Cluster 1: A, B, C

$$a(A) = [\text{dist}(A,B) + \text{dist}(A,C)] / 2 = (2 + 3) / 2 = \mathbf{2.5}$$

b(A): Distance moyenne au cluster le plus proche (Cluster 2)

Points du Cluster 2: D, E

$$b(A) = [\text{dist}(A,D) + \text{dist}(A,E)] / 2 = (10 + 12) / 2 = \mathbf{11}$$



Calcul Silhouette - Exemple

Point A du Cluster 1:

a(A): Distance moyenne aux autres points du Cluster 1

Points du Cluster 1: A, B, C

$$a(A) = [\text{dist}(A,B) + \text{dist}(A,C)] / 2 = (2 + 3) / 2 = \mathbf{2.5}$$

b(A): Distance moyenne au cluster le plus proche (Cluster 2)

Points du Cluster 2: D, E

$$b(A) = [\text{dist}(A,D) + \text{dist}(A,E)] / 2 = (10 + 12) / 2 = \mathbf{11}$$

$$s(A) = (11 - 2.5) / 11 = 8.5 / 11 = \mathbf{0.77}$$

✓ Bon score! A est bien assigné au Cluster 1



Code Python - K-Means

```
# Importer les bibliothèques
from sklearn.cluster import KMeans
import numpy as np
import matplotlib.pyplot as plt

# Données (âge, revenu)
X = np.array([
    [25, 30], [30, 35], [45, 70],
    [50, 75], [28, 32]
])

# Créer le modèle K-Means avec K=2
kmeans = KMeans(n_clusters=2, random_state=42)
kmeans.fit(X)

# Prédiction (assignations)
labels = kmeans.labels_
print(f"Clusters: {labels}")

# Centres finaux
```



Visualiser les Clusters

```
# Visualisation des clusters
import matplotlib.pyplot as plt

# Scatter plot coloré par cluster
plt.figure(figsize=(10, 6))
plt.scatter(X[:, 0], X[:, 1], c=labels, cmap='viridis', s=100)

# Centres en rouge
plt.scatter(centres[:, 0], centres[:, 1],
            c='red', marker='X', s=200,
            label='Centres')

plt.xlabel('Âge')
plt.ylabel('Revenu (k€)')
plt.title('Segmentation clients - K-Means')
plt.legend()
plt.grid(True)
plt.show()

# Méthode du coude
```



Code Python - DBSCAN

```
# DBSCAN - Clustering par densité
from sklearn.cluster import DBSCAN

# Données
X = np.array([
    [1, 1], [2, 1], [1, 2], [2, 2], # Cluster dense
    [10, 10], [10, 11],           # Autre cluster
    [20, 20]                       # Outlier
])

# Créer DBSCAN
dbscan = DBSCAN(eps=2, min_samples=3)
labels = dbscan.fit_predict(X)

print(f"Labels: {labels}")
# Labels: [0, 0, 0, 0, 1, 1, -1]
# -1 = bruit/outlier

# Nombre de clusters (sans compter -1)
n_clusters = len(set(labels)) - (1 if -1 in labels else 0)
```

Projet Final - Segmentation E-commerce

Mission: Segmenter les clients d'une boutique en ligne



Projet Final - Segmentation E-commerce

Mission: Segmenter les clients d'une boutique en ligne

Données disponibles:

- Montant total dépensé
- Nombre d'achats
- Fréquence de visite (jours)
- Temps depuis dernier achat



Projet Final - Segmentation E-commerce

Mission: Segmenter les clients d'une boutique en ligne

Données disponibles:


- Montant total dépensé
- Nombre d'achats
- Fréquence de visite (jours)
- Temps depuis dernier achat

Objectifs:

1. Normaliser les données (échelles différentes!)
2. Déterminer K optimal (méthode du coude)
3. Appliquer K-Means
4. Interpréter les clusters (VIP? Occasionnels? Inactifs?)
5. Stratégie marketing pour chaque segment



Points clés à retenir





Points clés à retenir

1. 🎯 Clustering = découvrir des **groupes naturels** (non supervisé)



Points clés à retenir

1. 🎯 Clustering = découvrir des **groupes naturels** (non supervisé)
2. 📊 K-Means = rapide, simple, clusters sphériques



Points clés à retenir

1. 🎯 Clustering = découvrir des **groupes naturels** (non supervisé)
2. 📊 K-Means = rapide, simple, clusters sphériques
3. 🔗 Hiérarchique = dendrogramme, pas besoin de K



Points clés à retenir

1. 🎯 Clustering = découvrir des **groupes naturels** (non supervisé)
2. 📊 K-Means = rapide, simple, clusters sphériques
3. 🔗 Hiérarchique = dendrogramme, pas besoin de K
4. 🎯 DBSCAN = formes arbitraires, détecte outliers



Points clés à retenir

1. 🎯 Clustering = découvrir des **groupes naturels** (non supervisé)
2. 📊 K-Means = rapide, simple, clusters sphériques
3. 🔗 Hiérarchique = dendrogramme, pas besoin de K
4. 🎯 DBSCAN = formes arbitraires, détecte outliers
5. 📏 Méthode du coude pour choisir K



Points clés à retenir

1. 🎯 Clustering = découvrir des **groupes naturels** (non supervisé)
2. 📊 K-Means = rapide, simple, clusters sphériques
3. 🔗 Hiérarchique = dendrogramme, pas besoin de K
4. 🎯 DBSCAN = formes arbitraires, détecte outliers
5. 📏 Méthode du coude pour choisir K
6. ✅ Silhouette Score pour évaluer



Points clés à retenir

1. 🎯 Clustering = découvrir des **groupes naturels** (non supervisé)
2. 📊 K-Means = rapide, simple, clusters sphériques
3. 🔗 Hiérarchique = dendrogramme, pas besoin de K
4. 🎯 DBSCAN = formes arbitraires, détecte outliers
5. 📏 Méthode du coude pour choisir K
6. ✅ Silhouette Score pour évaluer
7. ⚠️ Normaliser les données avant clustering!

Pièges courants

Oublier la normalisation

Variables à échelles différentes → Distance biaisée!

Pièges courants

Oublier la normalisation

Variables à échelles différentes → Distance biaisée!

→ Toujours standardiser (StandardScaler)

Pièges courants

Oublier la normalisation

Variables à échelles différentes → Distance biaisée!

→ Toujours standardiser (StandardScaler)

Mauvais choix de K

Trop de clusters = sur-segmentation, trop peu = perte d'info

Pièges courants

Oublier la normalisation

Variables à échelles différentes → Distance biaisée!

→ Toujours standardiser (StandardScaler)

Mauvais choix de K

Trop de clusters = sur-segmentation, trop peu = perte d'info

→ Utiliser méthode du coude + connaissance métier

Pièges courants

Oublier la normalisation

Variables à échelles différentes → Distance biaisée!

→ Toujours standardiser (StandardScaler)

Mauvais choix de K

Trop de clusters = sur-segmentation, trop peu = perte d'info

→ Utiliser méthode du coude + connaissance métier

Ignorer la nature des données

K-Means pour formes complexes = mauvais résultats

Pièges courants

Oublier la normalisation

Variables à échelles différentes → Distance biaisée!

→ Toujours standardiser (StandardScaler)

Mauvais choix de K

Trop de clusters = sur-segmentation, trop peu = perte d'info

→ Utiliser méthode du coude + connaissance métier

Ignorer la nature des données

K-Means pour formes complexes = mauvais résultats

→ Visualiser d'abord, choisir l'algo adapté

Pièges courants

Oublier la normalisation

Variables à échelles différentes → Distance biaisée!

→ Toujours standardiser (StandardScaler)

Mauvais choix de K

Trop de clusters = sur-segmentation, trop peu = perte d'info

→ Utiliser méthode du coude + connaissance métier

Ignorer la nature des données

K-Means pour formes complexes = mauvais résultats

→ Visualiser d'abord, choisir l'algo adapté

Sur-interpréter les clusters

Les clusters sont des patterns statistiques, pas forcément causaux

Pièges courants

Oublier la normalisation

Variables à échelles différentes → Distance biaisée!

→ Toujours standardiser (StandardScaler)

Mauvais choix de K

Trop de clusters = sur-segmentation, trop peu = perte d'info

→ Utiliser méthode du coude + connaissance métier

Ignorer la nature des données

K-Means pour formes complexes = mauvais résultats

→ Visualiser d'abord, choisir l'algo adapté

Sur-interpréter les clusters

Les clusters sont des patterns statistiques, pas forcément causaux

→ Valider avec experts métier



Applications Avancées



Compression d'images

Clustering des couleurs (K-Means)

Réduire 16M couleurs → K couleurs



Organisation de documents

Clustering de textes similaires

Catégorisation automatique



Détection d'anomalies

Points isolés = anomalies

Fraudes, pannes, outliers



Bioinformatique

Clustering de gènes

Découverte de sous-types maladies

PCA - Principal Component Analysis

Problème : Comment visualiser des données à 10, 50, ou 100 dimensions?

PCA - Principal Component Analysis

Problème : Comment visualiser des données à 10, 50, ou 100 dimensions?

 **Solution** : Réduction de dimensionnalité

PCA transforme vos données en **composantes principales** (nouvelles dimensions)

Exemple : 7 features → 2 composantes principales (PC1, PC2)

PCA - Principal Component Analysis

Problème : Comment visualiser des données à 10, 50, ou 100 dimensions?

 **Solution** : Réduction de dimensionnalité

PCA transforme vos données en **composantes principales** (nouvelles dimensions)

Exemple : 7 features → 2 composantes principales (PC1, PC2)

 **Idée clé** :

Trouver les directions où les données varient **le plus**

→ Projeter les données sur ces directions

→ Garder l'essentiel de l'information avec moins de dimensions!



Comment fonctionne PCA?

Étapes de l'algorithme:



Comment fonctionne PCA?

Étapes de l'algorithme:

1. **Standardiser** les données (moyenne=0, écart-type=1)



Comment fonctionne PCA?

Étapes de l'algorithme:

1. **Standardiser** les données (moyenne=0, écart-type=1)
2. **Calculer** la matrice de covariance



Comment fonctionne PCA?

Étapes de l'algorithme:

1. **Standardiser** les données (moyenne=0, écart-type=1)
2. **Calculer** la matrice de covariance
3. **Extraire** les vecteurs propres (eigenvectors)



Comment fonctionne PCA?

Étapes de l'algorithme:

1. **Standardiser** les données (moyenne=0, écart-type=1)
2. **Calculer** la matrice de covariance
3. **Extraire** les vecteurs propres (eigenvectors)
4. **Trier** par valeurs propres décroissantes



Comment fonctionne PCA?

Étapes de l'algorithme:

1. **Standardiser** les données (moyenne=0, écart-type=1)
2. **Calculer** la matrice de covariance
3. **Extraire** les vecteurs propres (eigenvectors)
4. **Trier** par valeurs propres décroissantes
5. **Projeter** les données sur les K premiers vecteurs



Comment fonctionne PCA?

Étapes de l'algorithme:

1. **Standardiser** les données (moyenne=0, écart-type=1)
2. **Calculer** la matrice de covariance
3. **Extraire** les vecteurs propres (eigenvectors)
4. **Trier** par valeurs propres décroissantes
5. **Projeter** les données sur les K premiers vecteurs

Variance expliquée:

PC1 capture 40% variance, PC2 capture 25% variance...

→ 2 composantes = 65% de l'information totale!

👁️ PCA - Visualisation

Avant PCA : 7 dimensions (impossible à visualiser)

👁️ PCA - Visualisation

Avant PCA : 7 dimensions (impossible à visualiser)

	nb_achats	montant_total	panier_moyen	jours_depuis	nb_pages	taux_conv	taux_retour
0	15	3500.00	233.33	10	120	12.5	2.1
1	8	1200.00	150.00	45	80	10.0	5.3
2	3	400.00	133.33	200	25	8.0	12.0
...							

👁️ PCA - Visualisation

Avant PCA : 7 dimensions (impossible à visualiser)

	nb_achats	montant_total	panier_moyen	jours_depuis	nb_pages	taux_conv	taux_retour
0	15	3500.00	233.33	10	120	12.5	2.1
1	8	1200.00	150.00	45	80	10.0	5.3
2	3	400.00	133.33	200	25	8.0	12.0
...							

Après PCA : 2 dimensions (PC1, PC2)

👁️ PCA - Visualisation

Avant PCA : 7 dimensions (impossible à visualiser)

	nb_achats	montant_total	panier_moyen	jours_depuis	nb_pages	taux_conv	taux_retour
0	15	3500.00	233.33	10	120	12.5	2.1
1	8	1200.00	150.00	45	80	10.0	5.3
2	3	400.00	133.33	200	25	8.0	12.0
...							

Après PCA : 2 dimensions (PC1, PC2)

	PC1	PC2
0	2.45	-0.82
1	0.13	1.25
2	-1.89	-0.34
...		

👁️ PCA - Visualisation

Avant PCA : 7 dimensions (impossible à visualiser)

	nb_achats	montant_total	panier_moyen	jours_depuis	nb_pages	taux_conv	taux_retour
0	15	3500.00	233.33	10	120	12.5	2.1
1	8	1200.00	150.00	45	80	10.0	5.3
2	3	400.00	133.33	200	25	8.0	12.0
...							

Après PCA : 2 dimensions (PC1, PC2)

	PC1	PC2
0	2.45	-0.82
1	0.13	1.25
2	-1.89	-0.34
...		

✅ Maintenant on peut faire un scatter plot 2D!

PCA + Clustering =

Workflow typique :

PCA + Clustering =

Workflow typique :

1 Appliquer PCA → Réduire dimensions (ex: 10 → 2)

PCA + Clustering =

Workflow typique :

1 Appliquer PCA → Réduire dimensions (ex: 10 → 2)

2 Visualiser → Scatter plot des 2 composantes

PCA + Clustering =

Workflow typique :

1 Appliquer PCA → Réduire dimensions (ex: 10 → 2)

2 Visualiser → Scatter plot des 2 composantes

3 Appliquer clustering → K-Means sur données originales

PCA + Clustering =

Workflow typique :

1 **Appliquer PCA** → Réduire dimensions (ex: 10 → 2)

2 **Visualiser** → Scatter plot des 2 composantes

3 **Appliquer clustering** → K-Means sur données originales

4 **Colorer** → Afficher clusters sur le plot PCA

PCA + Clustering =

Workflow typique :

1 Appliquer PCA → Réduire dimensions (ex: 10 → 2)

2 Visualiser → Scatter plot des 2 composantes

3 Appliquer clustering → K-Means sur données originales

4 Colorer → Afficher clusters sur le plot PCA

⚠ Important : PCA pour **visualisation**, mais clustering sur **données originales**!



Code Python - PCA

```
# 1. Importer et préparer
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

# Standardiser (obligatoire!)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# 2. Appliquer PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)

# 3. Vérifier variance expliquée
print(f"Variance PC1: {pca.explained_variance_ratio_[0]:.2%}")
print(f"Variance PC2: {pca.explained_variance_ratio_[1]:.2%}")
print(f"Total: {pca.explained_variance_ratio_.sum():.2%}")

# 4. Visualiser avec clusters
import matplotlib.pyplot as plt
```

? Combien de composantes garder?

Méthode 1: Seuil de variance


Garder assez de composantes pour expliquer $\geq 80\text{-}90\%$ variance

? Combien de composantes garder?

Méthode 1: Seuil de variance

Garder assez de composantes pour expliquer $\geq 80\text{-}90\%$ variance

Méthode 2: Scree Plot (graphique du coude)




? Combien de composantes garder?

Méthode 1: Seuil de variance

Garder assez de composantes pour expliquer $\geq 80\text{-}90\%$ variance

Méthode 2: Scree Plot (graphique du coude)



💡 En pratique:

Pour visualisation → 2 ou 3 composantes

Pour réduire avant ML → Selon variance cumulée (80-95%)



PCA - Avantages & Limites

✓ Avantages

- Visualisation intuitive
- Réduction bruit
- Accélère algorithmes
- Détecte corrélations
- Pas de labels nécessaires

✗ Limites

- Relations linéaires seulement
- Perte d'information
- Composantes difficiles à interpréter
- Sensible aux outliers
- Nécessite standardisation



PCA - Avantages & Limites

✓ Avantages

- Visualisation intuitive
- Réduction bruit
- Accélère algorithmes
- Détecte corrélations
- Pas de labels nécessaires

✗ Limites

- Relations linéaires seulement
- Perte d'information
- Composantes difficiles à interpréter
- Sensible aux outliers
- Nécessite standardisation

💡 **Alternatives:** t-SNE, UMAP (non-linéaires) pour visualisation



Conclusion

"Le clustering révèle les structures cachées dans vos données, comme découvrir des constellations dans le ciel étoilé"



Conclusion

"Le clustering révèle les structures cachées dans vos données, comme découvrir des constellations dans le ciel étoilé"

Vous savez maintenant:

- Comprendre le clustering (non supervisé)
- Appliquer K-Means étape par étape
- Utiliser clustering hiérarchique et DBSCAN
- Choisir K et évaluer la qualité
- Réduire dimensions avec PCA
- Coder en Python avec scikit-learn
- Interpréter et utiliser les résultats



Conclusion

"Le clustering révèle les structures cachées dans vos données, comme découvrir des constellations dans le ciel étoilé"

Vous savez maintenant:

-  Comprendre le clustering (non supervisé)
-  Appliquer K-Means étape par étape
-  Utiliser clustering hiérarchique et DBSCAN
-  Choisir K et évaluer la qualité
-  Réduire dimensions avec PCA
-  Coder en Python avec scikit-learn
-  Interpréter et utiliser les résultats



Prêts à découvrir les patterns cachés!

Questions?

Joseph Azar

joseph.azar@univ-fcomte.fr

Université Marie Louis Pasteur



TD Pratique: Segmentation clients réelle



Dataset e-commerce fourni



Objectif: Créer des profils clients exploitables