

# La Régression Linéaire

Simple, Multiple et Polynomiale

**Joseph Azar**

Maître de conférences  
Université Marie Louis Pasteur  
Intelligence Artificielle - Semaine 3

# Plan de la présentation

---

# Plan de la présentation

---

1. 🤔 Qu'est-ce que la régression?

# Plan de la présentation

---

1. 🤔 Qu'est-ce que la régression?
2. 🎯 Cas d'usage et applications

# Plan de la présentation

---

1. 🤔 Qu'est-ce que la régression?
2. 🎯 Cas d'usage et applications
3. 📈 La régression linéaire simple

# Plan de la présentation

---

1. 🤔 Qu'est-ce que la régression?
2. 🎯 Cas d'usage et applications
3. 📈 La régression linéaire simple
4. ♟️ Les mathématiques derrière

# Plan de la présentation

---

1. 🤔 Qu'est-ce que la régression?
2. 🎯 Cas d'usage et applications
3. 📈 La régression linéaire simple
4. ♟️ Les mathématiques derrière
5. 📊 La régression linéaire multiple

# Plan de la présentation

---

1. 🤔 Qu'est-ce que la régression?
2. 🎯 Cas d'usage et applications
3. 📈 La régression linéaire simple
4. ♟️ Les mathématiques derrière
5. 📊 La régression linéaire multiple
6. 🔄 La régression polynomiale



# Plan de la présentation

---

1. 🤔 Qu'est-ce que la régression?
2. 🎯 Cas d'usage et applications
3. 📈 La régression linéaire simple
4. ♟️ Les mathématiques derrière
5. 📊 La régression linéaire multiple
6. 🔄 La régression polynomiale
7. ⚖️ Choisir le bon modèle

# Plan de la présentation

---

1. 🤔 Qu'est-ce que la régression?
2. 🎯 Cas d'usage et applications
3. 📈 La régression linéaire simple
4. ♟️ Les mathématiques derrière
5. 📊 La régression linéaire multiple
6. 🔄 La régression polynomiale
7. ⚖️ Choisir le bon modèle
8. 📏 Mesurer les performances



# Commençons par une histoire...

---

Marco, pizzaiolo à Besançon 🍕



# Commençons par une histoire...

**Marco, pizzaiolo à Besançon** 

Il remarque que plus il fait chaud , plus il vend de pizzas 



# Commençons par une histoire...

**Marco, pizzaiolo à Besançon** 🍕

Il remarque que plus il fait chaud ☀️, plus il vend de pizzas 📈

Mais comment prédire ses ventes de demain? 🤔



# Commençons par une histoire...

**Marco, pizzaiolo à Besançon** 🍕

Il remarque que plus il fait chaud ☀️, plus il vend de pizzas 📈

Mais comment prédire ses ventes de demain? 🤔

**La régression va l'aider!** 🎯



# Commençons par une histoire...

**Marco, pizzaiolo à Besançon** 🍕

Il remarque que plus il fait chaud ☀️, plus il vend de pizzas 📈

Mais comment prédire ses ventes de demain? 🤔

**La régression va l'aider!** 🎯

💡 La régression trouve la relation mathématique entre:

- La température (variable explicative)
- Les ventes de pizzas (variable à prédire)

# Qu'est-ce que la régression?

---

**Définition:** La régression est une technique pour modéliser et analyser la relation entre variables



# Qu'est-ce que la régression?

**Définition:** La régression est une technique pour modéliser et analyser la relation entre variables

## Objectif

Prédire une valeur **continue**

Ex: prix, température, note

## Pas de classification!

Classification = catégories

Ex: chat/chien, spam/pas spam

# Qu'est-ce que la régression?

**Définition:** La régression est une technique pour modéliser et analyser la relation entre variables

## Objectif

Prédire une valeur **continue**

Ex: prix, température, note

## Pas de classification!

Classification = catégories

Ex: chat/chien, spam/pas spam

## Exemples de régression:

- Prédire le prix d'une maison 🏠
- Estimer la note d'un étudiant 📝
- Prévoir les ventes du mois 💰



# Applications dans la vie réelle



## Tech & Business

- Netflix: temps de visionnage
- Uber: prix de la course
- Amazon: prévision des stocks



## Santé

- Progression d'une maladie
- Dosage de médicaments
- Espérance de vie



## Sciences

- Météo: température demain
- Physique: trajectoire d'objets
- Écologie: niveau de pollution



## Finance

- Prix des actions
- Risque de crédit
- Taux d'intérêt



# La famille des régressions



## Régression Linéaire

Relation en ligne droite (notre focus aujourd'hui)



## Régression Polynomiale

Relation courbe (on verra ça aussi!)



## Régression Logistique

Pour classification binaire (0 ou 1)



## Autres

Ridge, Lasso, Arbres de décision...



# La Régression Linéaire Simple


**Idée:** Trouver la meilleure ligne droite qui passe à travers nos points





# La Régression Linéaire Simple

**Idée:** Trouver la meilleure ligne droite qui passe à travers nos points










# La Régression Linéaire Simple

**Idée:** Trouver la meilleure ligne droite qui passe à travers nos points



Une seule variable X pour prédire Y



# L'équation magique

---

$$y = ax + b$$



# L'équation magique

$$y = ax + b$$

## Les composants:

- **y** : valeur à prédire
- **x** : variable explicative
- **a** : pente (coefficient)
- **b** : ordonnée à l'origine



## Exemple Pizza:

$$\text{Ventes} = 3 \times \text{Température} + 20$$

- $a = 3$  (3 pizzas de plus par degré)
- $b = 20$  (20 pizzas même à 0°C)



# Calculons ensemble!



**Scénario:** Heures d'étude vs Note à l'examen

| Étudiant | Heures d'étude (X) | Note /20 (Y) |
|----------|--------------------|--------------|
| Alice    | 2                  | 10           |
| Bob      | 3                  | 12           |
| Charlie  | 5                  | 16           |
| Diana    | 4                  | 14           |



# Calculons ensemble!



**Scénario:** Heures d'étude vs Note à l'examen

| Étudiant | Heures d'étude (X) | Note /20 (Y) |
|----------|--------------------|--------------|
| Alice    | 2                  | 10           |
| Bob      | 3                  | 12           |
| Charlie  | 5                  | 16           |
| Diana    | 4                  | 14           |

**Étape 1:** Calculer les moyennes

$$\bar{X} = (2 + 3 + 5 + 4) / 4 = \mathbf{3.5}$$

$$\bar{Y} = (10 + 12 + 16 + 14) / 4 = \mathbf{13}$$



## Calcul de la pente (a)

$$a = \frac{\sum [(x_i - \bar{X})(y_i - \bar{Y})]}{\sum [(x_i - \bar{X})^2]}$$



## Calcul de la pente (a)

$$a = \frac{\sum [(x_i - \bar{X})(y_i - \bar{Y})]}{\sum [(x_i - \bar{X})^2]}$$

| $x_i$   | $y_i$ | $x_i - \bar{X}$ | $y_i - \bar{Y}$ | $(x_i - \bar{X})(y_i - \bar{Y})$ | $(x_i - \bar{X})^2$ |
|---------|-------|-----------------|-----------------|----------------------------------|---------------------|
| 2       | 10    | -1.5            | -3              | 4.5                              | 2.25                |
| 3       | 12    | -0.5            | -1              | 0.5                              | 0.25                |
| 5       | 16    | 1.5             | 3               | 4.5                              | 2.25                |
| 4       | 14    | 0.5             | 1               | 0.5                              | 0.25                |
| Sommes: |       |                 |                 | 10                               | 5                   |





## Calcul de la pente (a)

$$a = \Sigma[(x_i - \bar{X})(y_i - \bar{Y})] / \Sigma[(x_i - \bar{X})^2]$$

| $x_i$   | $y_i$ | $x_i - \bar{X}$ | $y_i - \bar{Y}$ | $(x_i - \bar{X})(y_i - \bar{Y})$ | $(x_i - \bar{X})^2$ |
|---------|-------|-----------------|-----------------|----------------------------------|---------------------|
| 2       | 10    | -1.5            | -3              | 4.5                              | 2.25                |
| 3       | 12    | -0.5            | -1              | 0.5                              | 0.25                |
| 5       | 16    | 1.5             | 3               | 4.5                              | 2.25                |
| 4       | 14    | 0.5             | 1               | 0.5                              | 0.25                |
| Sommes: |       |                 |                 | 10                               | 5                   |

$$a = 10 / 5 = 2$$

$$b = \bar{Y} - a \times \bar{X} = 13 - 2 \times 3.5 = 6$$



## Calcul de la pente (a)

$$a = \Sigma[(x_i - \bar{X})(y_i - \bar{Y})] / \Sigma[(x_i - \bar{X})^2]$$

| $x_i$   | $y_i$ | $x_i - \bar{X}$ | $y_i - \bar{Y}$ | $(x_i - \bar{X})(y_i - \bar{Y})$ | $(x_i - \bar{X})^2$ |
|---------|-------|-----------------|-----------------|----------------------------------|---------------------|
| 2       | 10    | -1.5            | -3              | 4.5                              | 2.25                |
| 3       | 12    | -0.5            | -1              | 0.5                              | 0.25                |
| 5       | 16    | 1.5             | 3               | 4.5                              | 2.25                |
| 4       | 14    | 0.5             | 1               | 0.5                              | 0.25                |
| Sommes: |       |                 |                 | 10                               | 5                   |

$$a = 10 / 5 = 2$$

$$b = \bar{Y} - a \times \bar{X} = 13 - 2 \times 3.5 = 6$$

✅ **Équation finale:** Note = 2 × Heures + 6

💡 Chaque heure d'étude = +2 points!

# Faisons des prédictions!

---

$$\text{Note} = 2 \times \text{Heures} + 6$$

# Faisons des prédictions!

$$\text{Note} = 2 \times \text{Heures} + 6$$

**Emma veut étudier 6 heures. Quelle sera sa note?**

# Faisons des prédictions!

$$\text{Note} = 2 \times \text{Heures} + 6$$

**Emma veut étudier 6 heures. Quelle sera sa note?**

$$\text{Note} = 2 \times 6 + 6 = \mathbf{18/20} \img alt="party popper icon" data-bbox="591 396 613 428"/>$$

# Faisons des prédictions!

$$\text{Note} = 2 \times \text{Heures} + 6$$

**Emma veut étudier 6 heures. Quelle sera sa note?**

$$\text{Note} = 2 \times 6 + 6 = \mathbf{18/20}$$
 

**Fred n'étudie qu'1 heure. Et lui?**

# Faisons des prédictions!

$$\text{Note} = 2 \times \text{Heures} + 6$$

**Emma veut étudier 6 heures. Quelle sera sa note?**

$$\text{Note} = 2 \times 6 + 6 = \mathbf{18/20}$$
 🎉

**Fred n'étudie qu'1 heure. Et lui?**

$$\text{Note} = 2 \times 1 + 6 = \mathbf{8/20}$$
 😞

# Faisons des prédictions!

$$\text{Note} = 2 \times \text{Heures} + 6$$

**Emma veut étudier 6 heures. Quelle sera sa note?**

$$\text{Note} = 2 \times 6 + 6 = \mathbf{18/20}$$
 

**Fred n'étudie qu'1 heure. Et lui?**

$$\text{Note} = 2 \times 1 + 6 = \mathbf{8/20}$$
 

**! Attention!** Et si quelqu'un étudie 20 heures?



# Faisons des prédictions!

$$\text{Note} = 2 \times \text{Heures} + 6$$

**Emma veut étudier 6 heures. Quelle sera sa note?**

$$\text{Note} = 2 \times 6 + 6 = \mathbf{18/20}$$
 

**Fred n'étudie qu'1 heure. Et lui?**

$$\text{Note} = 2 \times 1 + 6 = \mathbf{8/20}$$
 

**! Attention!** Et si quelqu'un étudie 20 heures?

$$\text{Note} = 2 \times 20 + 6 = 46/20 \text{ ???}$$
 

# Faisons des prédictions!

$$\text{Note} = 2 \times \text{Heures} + 6$$

**Emma veut étudier 6 heures. Quelle sera sa note?**

$$\text{Note} = 2 \times 6 + 6 = \mathbf{18/20}$$
 🎉

**Fred n'étudie qu'1 heure. Et lui?**

$$\text{Note} = 2 \times 1 + 6 = \mathbf{8/20}$$
 😬

**⚠ Attention!** Et si quelqu'un étudie 20 heures?

$$\text{Note} = 2 \times 20 + 6 = 46/20 \text{ ???}$$
 🤔

→ Les modèles ont des **limites!**



# La Régression Linéaire Multiple

**Plusieurs variables** pour une meilleure prédiction!



# La Régression Linéaire Multiple

**Plusieurs variables** pour une meilleure prédiction!

$$y = a_1x_1 + a_2x_2 + a_3x_3 + \dots + b$$



# La Régression Linéaire Multiple

**Plusieurs variables** pour une meilleure prédiction!

$$y = a_1x_1 + a_2x_2 + a_3x_3 + \dots + b$$



**Exemple: Prix d'une maison**


$$\text{Prix} = 1000 \times \text{Surface} + 500 \times \text{NbChambres} + 2000 \times \text{Jardin} + 50000$$

- Surface en m<sup>2</sup>
- Nombre de chambres
- Jardin (0 ou 1)



# Visualisation en 3D

## Régression Linéaire Multiple







# Exemple: Note finale d'un étudiant

---

| Étudiant | Heures étude | Heures sommeil | Nb cafés | Note /20 |
|----------|--------------|----------------|----------|----------|
| Alice    | 5            | 8              | 1        | 16       |
| Bob      | 3            | 6              | 3        | 12       |
| Charlie  | 7            | 7              | 2        | 18       |
| Diana    | 2            | 9              | 0        | 14       |





## Exemple: Note finale d'un étudiant

| Étudiant | Heures étude | Heures sommeil | Nb cafés | Note /20 |
|----------|--------------|----------------|----------|----------|
| Alice    | 5            | 8              | 1        | 16       |
| Bob      | 3            | 6              | 3        | 12       |
| Charlie  | 7            | 7              | 2        | 18       |
| Diana    | 2            | 9              | 0        | 14       |

$$\text{Note} = 1.5 \times \text{Heures\_étude} + 0.8 \times \text{Heures\_sommeil} + 0.3 \times \text{Cafés} + 3$$



## Exemple: Note finale d'un étudiant

| Étudiant | Heures étude | Heures sommeil | Nb cafés | Note /20 |
|----------|--------------|----------------|----------|----------|
| Alice    | 5            | 8              | 1        | 16       |
| Bob      | 3            | 6              | 3        | 12       |
| Charlie  | 7            | 7              | 2        | 18       |
| Diana    | 2            | 9              | 0        | 14       |

$$\text{Note} = 1.5 \times \text{Heures\_étude} + 0.8 \times \text{Heures\_sommeil} + 0.3 \times \text{Cafés} + 3$$



Interprétation:

- +1h d'étude → +1.5 points
- +1h de sommeil → +0.8 points
- +1 café → +0.3 points



# Quand la ligne droite ne suffit pas...

---



**Problème:** Consommation d'essence vs Vitesse



# Quand la ligne droite ne suffit pas...

 **Problème:** Consommation d'essence vs Vitesse

À 50 km/h: 5L/100km 



# Quand la ligne droite ne suffit pas...

**Problème:** Consommation d'essence vs Vitesse

À 50 km/h: 5L/100km

À 90 km/h: 4L/100km (optimal)



# Quand la ligne droite ne suffit pas...



**Problème:** Consommation d'essence vs Vitesse

À 50 km/h: 5L/100km ✓

À 90 km/h: 4L/100km ✓ (optimal)

À 130 km/h: 7L/100km 📈



# Quand la ligne droite ne suffit pas...



**Problème:** Consommation d'essence vs Vitesse

À 50 km/h: 5L/100km ✓

À 90 km/h: 4L/100km ✓ (optimal)

À 130 km/h: 7L/100km 📈



Ce n'est pas une ligne droite! C'est une courbe!



# Quand la ligne droite ne suffit pas...

 **Problème:** Consommation d'essence vs Vitesse

À 50 km/h: 5L/100km 

À 90 km/h: 4L/100km  (optimal)

À 130 km/h: 7L/100km 

 Ce n'est pas une ligne droite! C'est une courbe!

 **Solution:** La régression polynomiale!



# La Régression Polynomiale

**Degré 2:**  $y = ax^2 + bx + c$

**Degré 3:**  $y = ax^3 + bx^2 + cx + d$

**Degré n:**  $y = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$



# La Régression Polynomiale

**Degré 2:**  $y = ax^2 + bx + c$

**Degré 3:**  $y = ax^3 + bx^2 + cx + d$

**Degré n:**  $y = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$

## ✓ Avantages

- Capture les relations courbes
- Plus flexible
- Meilleur ajustement




## ⚠ Attention

- Risque de sur-ajustement
- Plus complexe
- Moins interprétable



# L'impact du degré polynomial

## Impact du Degré Polynomial sur l'Ajustement



**Règle d'or:** Commencer simple, complexifier si nécessaire!



# Le dilemme du degré

| Problème                                 | Description          | Symptômes                              | Solution                |
|------------------------------------------|----------------------|----------------------------------------|-------------------------|
| <b>Sous-ajustement</b><br>(Underfitting) | Modèle trop simple   | Erreur élevée partout                  | Augmenter la complexité |
| <b>Bon ajustement</b>                    | Équilibre parfait    | Bonne généralisation                   | ✓ Parfait!              |
| <b>Sur-ajustement</b><br>(Overfitting)   | Modèle trop complexe | Parfait sur train,<br>mauvais sur test | Simplifier le modèle    |



# Le dilemme du degré

| Problème                                 | Description          | Symptômes                              | Solution                |
|------------------------------------------|----------------------|----------------------------------------|-------------------------|
| <b>Sous-ajustement</b><br>(Underfitting) | Modèle trop simple   | Erreur élevée partout                  | Augmenter la complexité |
| <b>Bon ajustement</b>                    | Équilibre parfait    | Bonne généralisation                   | ✓ Parfait!              |
| <b>Sur-ajustement</b><br>(Overfitting)   | Modèle trop complexe | Parfait sur train,<br>mauvais sur test | Simplifier le modèle    |



**Analogie:** Apprendre par cœur vs Comprendre

- Sous-ajustement = Ne pas assez étudier
- Sur-ajustement = Apprendre par cœur sans comprendre
- Bon ajustement = Comprendre les concepts



# Comment trouve-t-on les meilleurs coefficients?

## Méthode des Moindres Carrés

Minimiser la somme des erreurs au carré



# Comment trouve-t-on les meilleurs coefficients?

## Méthode des Moindres Carrés

Minimiser la somme des erreurs au carré

$$\text{Erreur} = \sum (y_{\text{réel}} - y_{\text{prédit}})^2$$



# Comment trouve-t-on les meilleurs coefficients?

## Méthode des Moindres Carrés

Minimiser la somme des erreurs au carré

$$\text{Erreur} = \sum (y_{\text{réel}} - y_{\text{prédit}})^2$$



### Intuition:

1. Essayer différentes droites
2. Calculer l'erreur pour chacune
3. Garder celle avec la plus petite erreur





# Comment trouve-t-on les meilleurs coefficients?

## Méthode des Moindres Carrés

Minimiser la somme des erreurs au carré

$$\text{Erreur} = \sum (y_{\text{réel}} - y_{\text{prédit}})^2$$



### Intuition:

1. Essayer différentes droites
2. Calculer l'erreur pour chacune
3. Garder celle avec la plus petite erreur





En pratique: Algorithmes d'optimisation (gradient descent)



# La fonction de coût

## Fonction de Coût et Optimisation



★ L'étoile rouge = minimum = meilleurs paramètres!



# Comment mesurer la performance?

## **MSE (Mean Squared Error)**

Moyenne des erreurs au carré

Plus c'est petit, mieux c'est!

## **RMSE (Root MSE)**

Racine de MSE (même unité que Y)

Plus interprétable

## **R<sup>2</sup> (Coefficient de détermination)**

% de variance expliquée (0 à 1)

1 = parfait, 0 = nul

# Le $R^2$ expliqué simplement

---

$R^2$  = Part de la variation expliquée par le modèle



# Le $R^2$ expliqué simplement

$R^2$  = Part de la variation expliquée par le modèle

## Interprétation:

- $R^2 = 0.95$  → Le modèle explique 95% des variations ✅
- $R^2 = 0.70$  → Le modèle explique 70% des variations 👍
- $R^2 = 0.30$  → Le modèle explique 30% des variations 😐
- $R^2 = 0.05$  → Le modèle n'explique rien 👎



# Le $R^2$ expliqué simplement

$R^2$  = Part de la variation expliquée par le modèle



## Interprétation:

- $R^2 = 0.95$  → Le modèle explique 95% des variations ✓
- $R^2 = 0.70$  → Le modèle explique 70% des variations 👍
- $R^2 = 0.30$  → Le modèle explique 30% des variations 😐
- $R^2 = 0.05$  → Le modèle n'explique rien 👎



**Attention:** Un  $R^2$  élevé ne garantit pas un bon modèle!


Il peut y avoir sur-ajustement



# L'analyse des résidus


**Résidu** = Valeur réelle - Valeur prédite

Analyse des Résidus



# L'analyse des résidus

**Résidu** = Valeur réelle - Valeur prédite



✓ Bons résidus: Aléatoires autour de 0

✗ Mauvais résidus: Motifs visibles = problème!





# Quel modèle choisir?

---

Guide de décision:



# Quel modèle choisir?

## Guide de décision:

### 1 Commencer simple

Régression linéaire simple → Une variable



# Quel modèle choisir?

## Guide de décision:

### 1 Commencer simple

Régression linéaire simple → Une variable

### 2 Ajouter des variables si nécessaire

Régression multiple → Plusieurs variables



# Quel modèle choisir?

## Guide de décision:

### 1 Commencer simple

Régression linéaire simple → Une variable

### 2 Ajouter des variables si nécessaire

Régression multiple → Plusieurs variables

### 3 Considérer les courbes

Régression polynomiale → Si relation non-linéaire



# Quel modèle choisir?

## Guide de décision:

### 1 Commencer simple

Régression linéaire simple → Une variable

### 2 Ajouter des variables si nécessaire

Régression multiple → Plusieurs variables

### 3 Considérer les courbes

Régression polynomiale → Si relation non-linéaire

**⚠ Principe d'Occam:** Le modèle le plus simple qui fonctionne est le meilleur!

# À vous de jouer!

## Exercice: Temps vs Performance sportive

| Semaine entraînement | Temps course (sec) |
|----------------------|--------------------|
| 1                    | 120                |
| 2                    | 115                |
| 3                    | 112                |
| 4                    | 110                |

# À vous de jouer!

## Exercice: Temps vs Performance sportive

| Semaine entraînement | Temps course (sec) |
|----------------------|--------------------|
| 1                    | 120                |
| 2                    | 115                |
| 3                    | 112                |
| 4                    | 110                |

### Questions:

1. Quelle est la relation?
2. Prédire le temps après 6 semaines
3. Quand atteindra-t-il 100 secondes?

# À vous de jouer!

## Exercice: Temps vs Performance sportive

| Semaine entraînement | Temps course (sec) |
|----------------------|--------------------|
| 1                    | 120                |
| 2                    | 115                |
| 3                    | 112                |
| 4                    | 110                |

### Questions:

1. Quelle est la relation?
2. Prédire le temps après 6 semaines
3. Quand atteindra-t-il 100 secondes?

 Indice: Temps  $\approx 123 - 3.5 \times$  Semaines



# Les pièges à éviter

---

## **Extrapolation excessive**

Ne pas prédire trop loin des données d'entraînement

## **Corrélation $\neq$ Causalité**

Glaces vendues vs Noyades (les deux augmentent en été!)

## **Ignorer les outliers**

Un point aberrant peut tout fausser

## **Oublier de valider**

Toujours tester sur des données non vues!



# Cas pratique: Prédire le score d'un jeu vidéo

---

## Variables disponibles:

- Heures jouées
- Niveau du personnage
- Nombre d'items collectés
- Expérience du joueur (débutant/expert)



# Cas pratique: Prédire le score d'un jeu vidéo

## Variables disponibles:

- Heures jouées
- Niveau du personnage
- Nombre d'items collectés
- Expérience du joueur (débutant/expert)

## Approche étape par étape:

1. Visualiser les données (graphiques)
2. Tester régression simple (heures → score)
3. Ajouter variables (régression multiple)
4. Vérifier si relation linéaire
5. Évaluer avec  $R^2$  et résidus



# En Python, c'est simple!

```
# Importer les bibliothèques
from sklearn.linear_model import LinearRegression
import numpy as np

# Données d'exemple
X = np.array([[2], [3], [5], [4]]) # Heures d'étude
y = np.array([10, 12, 16, 14])     # Notes

# Créer et entraîner le modèle
model = LinearRegression()
model.fit(X, y)

# Coefficients
print(f"Pente: {model.coef_[0]:.2f}")
print(f"Ordonnée: {model.intercept_:.2f}")

# Prédiction
X_new = np.array([[6]]) # 6 heures d'étude
prediction = model.predict(X_new)
print(f"Prédiction: {prediction[0]:.1f}/20")
```



# En Python, c'est simple!

```
# Importer les bibliothèques
from sklearn.linear_model import LinearRegression
import numpy as np

# Données d'exemple
X = np.array([[2], [3], [5], [4]]) # Heures d'étude
y = np.array([10, 12, 16, 14])     # Notes

# Créer et entraîner le modèle
model = LinearRegression()
model.fit(X, y)

# Coefficients
print(f"Pente: {model.coef_[0]:.2f}")
print(f"Ordonnée: {model.intercept_:.2f}")

# Prédiction
X_new = np.array([[6]]) # 6 heures d'étude
prediction = model.predict(X_new)
print(f"Prédiction: {prediction[0]:.1f}/20")
```

✨ 5 lignes de code pour une régression!



# Régression Polynomiale

```
# Pour une régression polynomiale
from sklearn.preprocessing import PolynomialFeatures

# Transformer X en X, X2, X3
poly = PolynomialFeatures(degree=3)
X_poly = poly.fit_transform(X)

# Entraîner sur les features polynomiales
model_poly = LinearRegression()
model_poly.fit(X_poly, y)

# Prédiction
X_new_poly = poly.transform([[6]])
prediction_poly = model_poly.predict(X_new_poly)
```



# Régression Polynomiale

```
# Pour une régression polynomiale
from sklearn.preprocessing import PolynomialFeatures

# Transformer X en X, X2, X3
poly = PolynomialFeatures(degree=3)
X_poly = poly.fit_transform(X)

# Entraîner sur les features polynomiales
model_poly = LinearRegression()
model_poly.fit(X_poly, y)


# Prédiction
X_new_poly = poly.transform([[6]])
prediction_poly = model_poly.predict(X_new_poly)
```

💡 Astuce: PolynomialFeatures transforme X en  $[1, X, X^2, X^3]$



## Points clés à retenir

---







# Points clés à retenir

1.  La régression trouve des **relations** entre variables



# Points clés à retenir

---

1.  La régression trouve des **relations** entre variables
2.  Linéaire simple = une droite, une variable



# Points clés à retenir

1.  La régression trouve des **relations** entre variables
2.  Linéaire simple = une droite, une variable
3.  Multiple = plusieurs variables explicatives



# Points clés à retenir

1.  La régression trouve des **relations** entre variables
2.  Linéaire simple = une droite, une variable
3.  Multiple = plusieurs variables explicatives
4.  Polynomiale = pour les relations courbes



# Points clés à retenir

1.  La régression trouve des **relations** entre variables
2.  Linéaire simple = une droite, une variable
3.  Multiple = plusieurs variables explicatives
4.  Polynomiale = pour les relations courbes
5.  Équilibre entre simplicité et précision



# Points clés à retenir

1.  La régression trouve des **relations** entre variables
2.  Linéaire simple = une droite, une variable
3.  Multiple = plusieurs variables explicatives
4.  Polynomiale = pour les relations courbes
5.  Équilibre entre simplicité et précision
6.  Toujours évaluer avec métriques ( $R^2$ , MSE)



# Points clés à retenir

1.  La régression trouve des **relations** entre variables
2.  Linéaire simple = une droite, une variable
3.  Multiple = plusieurs variables explicatives
4.  Polynomiale = pour les relations courbes
5.  Équilibre entre simplicité et précision
6.  Toujours évaluer avec métriques ( $R^2$ , MSE)
7.  Commencer simple, complexifier si nécessaire



# Pour aller plus loin...

---



## Techniques avancées

- Régression Ridge (L2)
- Régression Lasso (L1)
- Elastic Net (L1 + L2)
- Régression robuste



## Applications ML

- Séries temporelles
- Réseaux de neurones
- Arbres de régression
- Random Forest





# Pour aller plus loin...



## Techniques avancées

- Régression Ridge (L2)
- Régression Lasso (L1)
- Elastic Net (L1 + L2)
- Régression robuste



## Applications ML

- Séries temporelles
- Réseaux de neurones
- Arbres de régression
- Random Forest



La régression linéaire est la base de beaucoup d'algorithmes plus complexes!



## Quiz rapide!

---

**Q1:** Quelle régression pour prédire le prix d'une voiture avec: âge, kilométrage, marque?



## Quiz rapide!

**Q1:** Quelle régression pour prédire le prix d'une voiture avec: âge, kilométrage, marque?

☒ Régression **multiple** (plusieurs variables)



## Quiz rapide!

**Q1:** Quelle régression pour prédire le prix d'une voiture avec: âge, kilométrage, marque?

✓ Régression **multiple** (plusieurs variables)

**Q2:** Mon  $R^2 = 0.99$  sur les données d'entraînement. C'est bien?

# Quiz rapide!

**Q1:** Quelle régression pour prédire le prix d'une voiture avec: âge, kilométrage, marque?

☒ Régression **multiple** (plusieurs variables)

**Q2:** Mon  $R^2 = 0.99$  sur les données d'entraînement. C'est bien?

 Attention au **sur-ajustement**! Tester sur nouvelles données



## Quiz rapide!

**Q1:** Quelle régression pour prédire le prix d'une voiture avec: âge, kilométrage, marque?

✅ Régression **multiple** (plusieurs variables)

**Q2:** Mon  $R^2 = 0.99$  sur les données d'entraînement. C'est bien?

⚠️ Attention au **sur-ajustement**! Tester sur nouvelles données

**Q3:** Vitesse du vent vs Production éolienne (courbe en S). Quel modèle?



# Quiz rapide!

**Q1:** Quelle régression pour prédire le prix d'une voiture avec: âge, kilométrage, marque?

✅ Régression **multiple** (plusieurs variables)

**Q2:** Mon  $R^2 = 0.99$  sur les données d'entraînement. C'est bien?

⚠️ Attention au **sur-ajustement**! Tester sur nouvelles données

**Q3:** Vitesse du vent vs Production éolienne (courbe en S). Quel modèle?

✅ Régression **polynomiale** (relation courbe)

# Conclusion

---

"Tous les modèles sont faux, mais certains sont utiles"

- George Box





# Conclusion

"Tous les modèles sont faux, mais certains sont utiles"

- George Box

## **Vous savez maintenant:**

-  Ce qu'est la régression et quand l'utiliser
-  Calculer une régression à la main
-  Différencier simple, multiple et polynomiale
-  Évaluer la qualité d'un modèle
-  Éviter les pièges courants



# Conclusion

"Tous les modèles sont faux, mais certains sont utiles"

- George Box

## **Vous savez maintenant:**

-  Ce qu'est la régression et quand l'utiliser
-  Calculer une régression à la main
-  Différencier simple, multiple et polynomiale
-  Évaluer la qualité d'un modèle
-  Éviter les pièges courants



**Prêts pour le TD?**

# Questions?

**Joseph Azar**

joseph.azar@univ-fcomte.fr

Université Marie Louis Pasteur



**Prochain TD:** Application pratique sur données réelles



Apportez vos ordinateurs!