

TD: PRÉTRAITEMENT DES DONNÉES

ATELIER PRATIQUE - PAPIER & CRAYON → CODE

Joseph Azar

Intelligence Artificielle - Travaux Dirigés

OBJECTIFS DE L'ATELIER

OBJECTIFS DE L'ATELIER

-  Comprendre le prétraitement **sans coder**

OBJECTIFS DE L'ATELIER

-  Comprendre le prétraitement **sans coder**
-  Calculer manuellement chaque transformation

OBJECTIFS DE L'ATELIER

-  Comprendre le prétraitement **sans coder**
-  Calculer manuellement chaque transformation
-  Identifier les problèmes dans les données

OBJECTIFS DE L'ATELIER

-  Comprendre le prétraitement **sans coder**
-  Calculer manuellement chaque transformation
-  Identifier les problèmes dans les données
-  Traduire en code Python après compréhension

OBJECTIFS DE L'ATELIER

-  Comprendre le prétraitement **sans coder**
-  Calculer manuellement chaque transformation
-  Identifier les problèmes dans les données
-  Traduire en code Python après compréhension

Matériel nécessaire: Papier, crayon, calculatrice

NOTRE DATASET: DATA.CSV

ID	Country	Age	Salary	Education	Experience	Purchased
1	France	44	72000	Master	16	No
2	Spain	27	48000	Bachelor	5	Yes
3	Germany	30	54000	Bachelor	8	No
4	Spain	38	61000	Master	12	No
5	Germany	40	?	PhD	10	Yes
6	France	35	58000	Bachelor	13	Yes
7	Spain	?	52000	Bachelor	7	No
8	France	48	79000	Master	22	Yes
9	Germany	50	83000	PhD	20	No
10	France	37	67000	Master	11	Yes
...	...	...	...	...	...	...
14	USA	45	250000	PhD	15	Yes
20	USA	28	480000	PhD	2	Yes
30	UK	35	320000	Bachelor	13	No



EXERCICE 1: IDENTIFIER LES PROBLÈMES

Prenez 5 minutes.

Sur votre papier, listez TOUS les problèmes que vous identifiez dans ce dataset.

Soyez précis (quelle colonne, quel type de problème).



EXERCICE 1: IDENTIFIER LES PROBLÈMES

Prenez 5 minutes.

Sur votre papier, listez TOUS les problèmes que vous identifiez dans ce dataset.

Soyez précis (quelle colonne, quel type de problème).

Temps écoulé? Comparons vos réponses...

SOLUTIONS - PROBLÈMES À IDENTIFIER

1. **Valeurs manquantes:** Age (ligne 7), Salary (ligne 5)
2. **Valeurs aberrantes:** Salaires très élevés (250k, 320k, 480k)
3. **Variables catégorielles:** Country (nominal), Education (ordinal)
4. **Corrélation potentielle:** Age et Experience semblent liés
5. **Échelles différentes:** Age (20-50) vs Salary (48k-480k)
6. **Target binaire:** Purchased (Yes/No) nécessite encodage

SOLUTIONS - PROBLÈMES À IDENTIFIER

1. **Valeurs manquantes:** Age (ligne 7), Salary (ligne 5)
2. **Valeurs aberrantes:** Salaires très élevés (250k, 320k, 480k)
3. **Variables catégorielles:** Country (nominal), Education (ordinal)
4. **Corrélation potentielle:** Age et Experience semblent liés
5. **Échelles différentes:** Age (20-50) vs Salary (48k-480k)
6. **Target binaire:** Purchased (Yes/No) nécessite encodage

SOLUTIONS - PROBLÈMES À IDENTIFIER

1. **Valeurs manquantes:** Age (ligne 7), Salary (ligne 5)
2. **Valeurs aberrantes: Salaires très élevés (250k, 320k, 480k)**
3. **Variables catégorielles:** Country (nominal), Education (ordinal)
4. **Corrélation potentielle:** Age et Experience semblent liés
5. **Échelles différentes:** Age (20-50) vs Salary (48k-480k)
6. **Target binaire:** Purchased (Yes/No) nécessite encodage

SOLUTIONS - PROBLÈMES À IDENTIFIER

1. **Valeurs manquantes:** Age (ligne 7), Salary (ligne 5)
2. **Valeurs aberrantes:** Salaires très élevés (250k, 320k, 480k)
3. **Variables catégorielles: Country (nominal), Education (ordinal)**
4. **Corrélation potentielle:** Age et Experience semblent liés
5. **Échelles différentes:** Age (20-50) vs Salary (48k-480k)
6. **Target binaire:** Purchased (Yes/No) nécessite encodage

SOLUTIONS - PROBLÈMES À IDENTIFIER

1. **Valeurs manquantes:** Age (ligne 7), Salary (ligne 5)
2. **Valeurs aberrantes:** Salaires très élevés (250k, 320k, 480k)
3. **Variables catégorielles:** Country (nominal), Education (ordinal)
4. **Corrélation potentielle: Age et Experience semblent liés**
5. **Échelles différentes:** Age (20-50) vs Salary (48k-480k)
6. **Target binaire:** Purchased (Yes/No) nécessite encodage

SOLUTIONS - PROBLÈMES À IDENTIFIER

1. **Valeurs manquantes:** Age (ligne 7), Salary (ligne 5)
2. **Valeurs aberrantes:** Salaires très élevés (250k, 320k, 480k)
3. **Variables catégorielles:** Country (nominal), Education (ordinal)
4. **Corrélation potentielle:** Age et Experience semblent liés
5. **Échelles différentes: Age (20-50) vs Salary (48k-480k)**
6. **Target binaire:** Purchased (Yes/No) nécessite encodage

SOLUTIONS - PROBLÈMES À IDENTIFIER

1. **Valeurs manquantes:** Age (ligne 7), Salary (ligne 5)
2. **Valeurs aberrantes:** Salaires très élevés (250k, 320k, 480k)
3. **Variables catégorielles:** Country (nominal), Education (ordinal)
4. **Corrélation potentielle:** Age et Experience semblent liés
5. **Échelles différentes:** Age (20-50) vs Salary (48k-480k)
6. **Target binaire: Purchased (Yes/No) nécessite encodage**

PROBLÈME 1: VALEURS MANQUANTES

CALCUL MANUEL DE L'IMPUTATION

Données Age: 44, 27, 30, 38, 40, 35, ?, 48, 50, 37



PROBLÈME 1: VALEURS MANQUANTES

CALCUL MANUEL DE L'IMPUTATION

Données Age: 44, 27, 30, 38, 40, 35, ?, 48, 50, 37

Moyenne :

$$\mu = (44 + 27 + 30 + 38 + 40 + 35 + 48 + 50 + 37) \div 9$$

$$\mu = 349 \div 9 = \mathbf{38.78}$$



PROBLÈME 1: VALEURS MANQUANTES

CALCUL MANUEL DE L'IMPUTATION

Données Age: 44, 27, 30, 38, 40, 35, ?, 48, 50, 37

Moyenne :

$$\mu = (44 + 27 + 30 + 38 + 40 + 35 + 48 + 50 + 37) \div 9$$

$$\mu = 349 \div 9 = \mathbf{38.78}$$

Médiane :

Tri: 27, 30, 35, 37, 38, 40, 44, 48, 50

Médiane = **38**

PROBLÈME 1: VALEURS MANQUANTES

CALCUL MANUEL DE L'IMPUTATION

Données Age: 44, 27, 30, 38, 40, 35, ?, 48, 50, 37

Moyenne :

$$\mu = (44 + 27 + 30 + 38 + 40 + 35 + 48 + 50 + 37) \div 9$$
$$\mu = 349 \div 9 = \mathbf{38.78}$$

Médiane :

Tri: 27, 30, 35, 37, 38, 40, 44, 48, 50

Médiane = **38**

 **Choix:** Médiane (38) car robuste aux valeurs extrêmes



EXERCICE 2: IMPUTATION

Calculez la moyenne et la médiane pour ces salaires

ID	Salary
1	72000
2	48000
3	54000
4	61000
5	?
6	58000



EXERCICE 2: IMPUTATION

Calculez la moyenne et la médiane pour ces salaires

ID	Salary
1	72000
2	48000
3	54000
4	61000
5	?
6	58000

Solution:

Moyenne = $(72000 + 48000 + 54000 + 61000 + 58000) \div 5 = \mathbf{58600}$

Médiane après tri = **58000**



PROBLÈME 2: DÉTECTION DES OUTLIERS

ÉTAPE 1: CALCULER LA MOYENNE (M)

Salaires: 72k, 48k, 54k, 61k, 58k, 52k, 79k, 83k, 67k, 250k, 480k



PROBLÈME 2: DÉTECTION DES OUTLIERS

ÉTAPE 1: CALCULER LA MOYENNE (M)

Salaires: 72k, 48k, 54k, 61k, 58k, 52k, 79k, 83k, 67k, 250k, 480k

$$\text{Moyenne } \mu = \Sigma(x_i) / n$$

$$\begin{aligned} &= (72 + 48 + 54 + 61 + 58 + 52 + 79 + 83 + 67 + 250 + \\ &\quad 480) / 11 \\ &= 1304 / 11 \\ &= \mathbf{118.5k} \end{aligned}$$



PROBLÈME 2: DÉTECTION DES OUTLIERS

ÉTAPE 1: CALCULER LA MOYENNE (M)

Salaires: 72k, 48k, 54k, 61k, 58k, 52k, 79k, 83k, 67k, 250k, 480k

$$\text{Moyenne } \mu = \Sigma(x_i) / n$$

$$\begin{aligned} &= (72 + 48 + 54 + 61 + 58 + 52 + 79 + 83 + 67 + 250 + \\ &\quad 480) / 11 \\ &= 1304 / 11 \\ &= \mathbf{118.5k} \end{aligned}$$



Remarque: La moyenne est très élevée à cause des outliers!
Sans 250k et 480k: moyenne = 63k



CALCUL DE L'ÉCART-TYPE (Σ)

$$\sigma = \sqrt{(\Sigma (x_i - \mu)^2 / n)}$$



CALCUL DE L'ÉCART-TYPE (Σ)

$$\sigma = \sqrt{(\Sigma (x_i - \mu)^2 / n)}$$

Salaire (xi)	xi - μ	(xi - μ) ²
72k	-46.5	2162
48k	-70.5	4970
54k	-64.5	4160
...	...	...
250k	131.5	17,292
480k	361.5	130,682
Somme:		177,636



CALCUL DE L'ÉCART-TYPE (Σ)

$$\sigma = \sqrt{(\Sigma (x_i - \mu)^2 / n)}$$

Salaire (xi)	xi - μ	(xi - μ) ²
72k	-46.5	2162
48k	-70.5	4970
54k	-64.5	4160
...	...	...
250k	131.5	17,292
480k	361.5	130,682
Somme:		177,636

$$\sigma = \sqrt{(177,636 / 11)} = \sqrt{16,149} = \mathbf{127k}$$



APPLICATION DU Z-SCORE

$$Z = (X - \mu) / \sigma$$

Avec $\mu = 118.5k$ et $\sigma = 127k$



APPLICATION DU Z-SCORE

$$Z = (X - \mu) / \sigma$$

Avec $\mu = 118.5k$ et $\sigma = 127k$

CALCUL POUR CHAQUE VALEUR SUSPECTE:

Pour 250k:

$$Z = (250 - 118.5) / 127 = 131.5 / 127 = 1.04$$

Pour 480k:

$$Z = (480 - 118.5) / 127 = 361.5 / 127 = 2.85$$



APPLICATION DU Z-SCORE

$$Z = (X - \mu) / \sigma$$

Avec $\mu = 118.5k$ et $\sigma = 127k$

CALCUL POUR CHAQUE VALEUR SUSPECTE:

Pour 250k:

$$Z = (250 - 118.5) / 127 = 131.5 / 127 = 1.04$$

Pour 480k:

$$Z = (480 - 118.5) / 127 = 361.5 / 127 = 2.85$$



Avec le seuil $|Z| > 3$:

- 250k: $Z = 1.04 < 3 \rightarrow$ Pas un outlier (selon ce critère)
- 480k: $Z = 2.85 < 3 \rightarrow$ Pas un outlier (mais proche!)



LA COURBE DE GAUSS (DISTRIBUTION NORMALE)

QU'EST-CE QUE C'EST?



LA COURBE DE GAUSS (DISTRIBUTION NORMALE)

QU'EST-CE QUE C'EST?


La courbe de Gauss représente comment les données se distribuent naturellement autour de la moyenne dans beaucoup de phénomènes



LA COURBE DE GAUSS (DISTRIBUTION NORMALE)

QU'EST-CE QUE C'EST?

La courbe de Gauss représente comment les données se distribuent naturellement autour de la moyenne dans beaucoup de phénomènes






LA COURBE DE GAUSS (DISTRIBUTION NORMALE)

QU'EST-CE QUE C'EST?

La courbe de Gauss représente comment les données se distribuent naturellement autour de la moyenne dans beaucoup de phénomènes



Exemples dans la vie:

- Taille des personnes
- Notes d'examen
- QI
- Erreurs de mesure



LES 3 ZONES DE LA COURBE DE GAUSS



LES 3 ZONES DE LA COURBE DE GAUSS

Zone 1: $\mu \pm 1\sigma$ (68% des données)

La zone "normale" - la majorité des valeurs



LES 3 ZONES DE LA COURBE DE GAUSS

Zone 1: $\mu \pm 1\sigma$ (68% des données)

La zone "normale" - la majorité des valeurs

Zone 2: $\mu \pm 2\sigma$ (95% des données)

Zone élargie - inclut presque toutes les valeurs normales



LES 3 ZONES DE LA COURBE DE GAUSS

Zone 1: $\mu \pm 1\sigma$ (68% des données)

La zone "normale" - la majorité des valeurs

Zone 2: $\mu \pm 2\sigma$ (95% des données)

Zone élargie - inclut presque toutes les valeurs normales

Zone 3: $\mu \pm 3\sigma$ (99.7% des données)

Zone maximale - au-delà = valeurs exceptionnelles (outliers)



LES 3 ZONES DE LA COURBE DE GAUSS

Zone 1: $\mu \pm 1\sigma$ (68% des données)


La zone "normale" - la majorité des valeurs

Zone 2: $\mu \pm 2\sigma$ (95% des données)

Zone élargie - inclut presque toutes les valeurs normales

Zone 3: $\mu \pm 3\sigma$ (99.7% des données)

Zone maximale - au-delà = valeurs exceptionnelles (outliers)



? POURQUOI LE SEUIL DE 3?

Règle empirique (68-95-99.7) :

- $\mu \pm 1\sigma \rightarrow 68\%$ des données
- $\mu \pm 2\sigma \rightarrow 95\%$ des données
- $\mu \pm 3\sigma \rightarrow 99.7\%$ des données

? POURQUOI LE SEUIL DE 3?

Règle empirique (68-95-99.7) :

- $\mu \pm 1\sigma \rightarrow 68\%$ des données
- $\mu \pm 2\sigma \rightarrow 95\%$ des données
- $\mu \pm 3\sigma \rightarrow 99.7\%$ des données



Interprétation:

Si $Z > 3$: seulement 0.3% de chance d'être normale
→ Très probablement un outlier!

? POURQUOI LE SEUIL DE 3?

Règle empirique (68-95-99.7) :

- $\mu \pm 1\sigma \rightarrow 68\%$ des données
- $\mu \pm 2\sigma \rightarrow 95\%$ des données
- $\mu \pm 3\sigma \rightarrow 99.7\%$ des données



Interprétation:

Si $Z > 3$: seulement 0.3% de chance d'être normale
→ Très probablement un outlier!


Exemple - Taille humaine:

$$\mu = 170\text{cm}, \sigma = 10\text{cm}$$

- Zone 1 ($\pm 1\sigma$): 160-180cm → 68% des gens
- Zone 2 ($\pm 2\sigma$): 150-190cm → 95% des gens
- Zone 3 ($\pm 3\sigma$): 140-200cm → 99.7% des gens
- $Z > 3$: Plus de 200cm → Très rare (0.3%)!




VISUALISATION COMPLÈTE





VISUALISATION COMPLÈTE



Distance de μ	% inclus	% exclus	Décision
$< 3\sigma$	99.7%	0.3%	Normal
$> 3\sigma$	0.3%	99.7%	Outlier!



QU'EST-CE QU'UN QUARTILE?

COMPRENDRE LES QUARTILES AVEC UN EXEMPLE SIMPLE



QU'EST-CE QU'UN QUARTILE?

COMPRENDRE LES QUARTILES AVEC UN EXEMPLE SIMPLE

Imaginez 100 étudiants classés par taille (du plus petit au plus grand)



QU'EST-CE QU'UN QUARTILE?

COMPRENDRE LES QUARTILES AVEC UN EXEMPLE SIMPLE

Imaginez 100 étudiants classés par taille (du plus petit au plus grand)

Les Quartiles divisent les données en 4 parties égales:

- **Q1 (1er quartile)** = Position 25 → 25% sont plus petits
- **Q2 (2e quartile)** = Position 50 → 50% sont plus petits (MÉDIANE)
- **Q3 (3e quartile)** = Position 75 → 75% sont plus petits



QU'EST-CE QU'UN QUARTILE?

COMPRENDRE LES QUARTILES AVEC UN EXEMPLE SIMPLE

Imaginez 100 étudiants classés par taille (du plus petit au plus grand)

Les Quartiles divisent les données en 4 parties égales:

- **Q1 (1er quartile)** = Position 25 → 25% sont plus petits
- **Q2 (2e quartile)** = Position 50 → 50% sont plus petits (MÉDIANE)
- **Q3 (3e quartile)** = Position 75 → 75% sont plus petits



25% des
données

25% des
données

25% des
données

25% des
données



QU'EST-CE QU'UN QUARTILE?

COMPRENDRE LES QUARTILES AVEC UN EXEMPLE SIMPLE

Imaginez 100 étudiants classés par taille (du plus petit au plus grand)

Les Quartiles divisent les données en 4 parties égales:

- **Q1 (1er quartile)** = Position 25 → 25% sont plus petits
- **Q2 (2e quartile)** = Position 50 → 50% sont plus petits (MÉDIANE)
- **Q3 (3e quartile)** = Position 75 → 75% sont plus petits



25% des
données

25% des
données

25% des
données

25% des
données

💡 **Résumé:** Les quartiles sont comme des "bornes" qui séparent vos données triées en 4 groupes de taille égale (25% chacun)



CALCUL DES QUARTILES - ÉTAPES 1 & 2

Données: 48k, 52k, 54k, 58k, 61k, 67k, 72k, 79k, 83k, 250k, 320k, 480k



CALCUL DES QUARTILES - ÉTAPES 1 & 2

Données: 48k, 52k, 54k, 58k, 61k, 67k, 72k, 79k, 83k, 250k, 320k, 480k

ÉTAPE 1: TRIER LES DONNÉES

48,	52,	54,	58,	61,	67,	72,	79,	83,	250,	320,	480
Pos: 1	2	3	4	5	6	7	8	9	10	11	12

⚠ Valeurs extrêmes en orange!



CALCUL DES QUARTILES - ÉTAPES 1 & 2

Données: 48k, 52k, 54k, 58k, 61k, 67k, 72k, 79k, 83k, 250k, 320k, 480k

ÉTAPE 1: TRIER LES DONNÉES

48, 52, 54, 58, 61, 67, 72, 79, 83, 250, 320, 480
Pos: 1 2 3 4 5 6 7 8 9 10 11 12

⚠ Valeurs extrêmes en orange!

ÉTAPE 2: POSITIONS DES QUARTILES

$n = 12$ données

$$\text{Pos } Q1 = (n+1) \times 0.25 = 13 \times 0.25 = \mathbf{3.25}$$

$$\text{Pos } Q2 = (n+1) \times 0.50 = 13 \times 0.50 = \mathbf{6.5}$$

$$\text{Pos } Q3 = (n+1) \times 0.75 = 13 \times 0.75 = \mathbf{9.75}$$



CALCUL DES QUARTILES - ÉTAPE 3

TROUVER LES VALEURS AUX POSITIONS CALCULÉES



CALCUL DES QUARTILES - ÉTAPE 3

TROUVER LES VALEURS AUX POSITIONS CALCULÉES

Q1 (position 3.25):

Entre positions 3 et 4 → Entre 54 et 58

$$= 54 + 0.25 \times (58 - 54)$$

$$= 54 + 1 = 55k$$

✓ Dans les valeurs normales



CALCUL DES QUARTILES - ÉTAPE 3

TROUVER LES VALEURS AUX POSITIONS CALCULÉES

Q1 (position 3.25):

Entre positions 3 et 4 → Entre 54 et 58

$$= 54 + 0.25 \times (58 - 54)$$

$$= 54 + 1 = 55k$$

✓ Dans les valeurs normales

Q2 (position 6.5):

Entre positions 6 et 7 → Entre 67 et 72

$$= (67 + 72) / 2 = 69.5k$$

✓ Médiane dans les valeurs normales



CALCUL DES QUARTILES - ÉTAPE 3

TROUVER LES VALEURS AUX POSITIONS CALCULÉES

Q1 (position 3.25):

Entre positions 3 et 4 → Entre 54 et 58

$$= 54 + 0.25 \times (58 - 54)$$

$$= 54 + 1 = 55k$$

✓ Dans les valeurs normales

Q2 (position 6.5):

Entre positions 6 et 7 → Entre 67 et 72

$$= (67 + 72) / 2 = 69.5k$$

✓ Médiane dans les valeurs normales

Q3 (position 9.75):

Entre positions 9 et 10 → Entre 83 et 250

$$= 83 + 0.75 \times (250 - 83)$$

$$= 83 + 125.25 = 208.25k$$

⚠ ATTENTION: Influencé par l'outlier 250k!



PROBLÈME: OUTLIERS AFFECTENT Q3!

Observez comment les outliers influencent les quartiles

⚠ PROBLÈME: OUTLIERS AFFECTENT Q3!

Observez comment les outliers influencent les quartiles

SANS OUTLIERS (DONNÉES 1-9 SEULEMENT):

48, 52, 54, 58, 61, 67, 72, 79, 83

$Q1 \approx 54k, Q2 = 61k, Q3 \approx 79k$

$IQR = 79 - 54 = 25k \checkmark$ Raisonnable

⚠ PROBLÈME: OUTLIERS AFFECTENT Q3!

Observez comment les outliers influencent les quartiles

SANS OUTLIERS (DONNÉES 1-9 SEULEMENT):

48, 52, 54, 58, 61, 67, 72, 79, 83

$Q1 \approx 54k$, $Q2 = 61k$, $Q3 \approx 79k$

$IQR = 79 - 54 = 25k$ ✓ Raisonnable

AVEC OUTLIERS (TOUTES LES DONNÉES):

48, 52, 54, 58, 61, 67, 72, 79, 83, 250, 320, 480

$Q1 = 55k$, $Q2 = 69.5k$, $Q3 = 208.25k$

$IQR = 208.25 - 55 = 153.25k$ ⚠ Très large!

⚠ PROBLÈME: OUTLIERS AFFECTENT Q3!

Observez comment les outliers influencent les quartiles

SANS OUTLIERS (DONNÉES 1-9 SEULEMENT):

48, 52, 54, 58, 61, 67, 72, 79, 83

$Q1 \approx 54k$, $Q2 = 61k$, $Q3 \approx 79k$

$IQR = 79 - 54 = 25k$ ✓ Raisonnable

AVEC OUTLIERS (TOUTES LES DONNÉES):

48, 52, 54, 58, 61, 67, 72, 79, 83, 250, 320, 480

$Q1 = 55k$, $Q2 = 69.5k$, $Q3 = 208.25k$

$IQR = 208.25 - 55 = 153.25k$ ⚠ Très large!

💡 **Leçon:** Même l'IQR peut être affecté par des outliers extrêmes!
Solution: Parfois, il faut d'abord enlever les outliers évidents

avant de calculer l'IQR pour détecter les outliers plus subtils.



CALCUL DE L'IQR (ÉCART INTERQUARTILE)

IQR = Q3 - Q1 (écart entre 3e et 1er quartile)



CALCUL DE L'IQR (ÉCART INTERQUARTILE)

IQR = Q3 - Q1 (écart entre 3e et 1er quartile)

$Q1 = 55k, Q3 = 208.25k$

$IQR = 208.25 - 55 = 153.25k$



CALCUL DE L'IQR (ÉCART INTERQUARTILE)

IQR = Q3 - Q1 (écart entre 3e et 1er quartile)

$Q1 = 55k, Q3 = 208.25k$

IQR = 208.25 - 55 = 153.25k



Interprétation: L'IQR = zone centrale avec 50% des données




CALCUL DE L'IQR (ÉCART INTERQUARTILE)

$$\text{IQR} = Q3 - Q1 \text{ (écart entre 3e et 1er quartile)}$$

$$Q1 = 55k, \quad Q3 = 208.25k$$

$$\text{IQR} = 208.25 - 55 = 153.25k$$

💡 **Interprétation:** L'IQR = zone centrale avec 50% des données



DÉTECTION D'OUTLIERS AVEC LA RÈGLE $1.5 \times \text{IQR}$

Bornes outliers: $Q1 - 1.5 \times \text{IQR}$ et $Q3 + 1.5 \times \text{IQR}$



DÉTECTION D'OUTLIERS AVEC LA RÈGLE $1.5 \times \text{IQR}$

Bornes outliers: $Q1 - 1.5 \times \text{IQR}$ et $Q3 + 1.5 \times \text{IQR}$

Pourquoi 1.5? Règle de Tukey, capture ~99.3% des données normales



DÉTECTION D'OUTLIERS AVEC LA RÈGLE $1.5 \times \text{IQR}$

Bornes outliers: $Q1 - 1.5 \times \text{IQR}$ et $Q3 + 1.5 \times \text{IQR}$

Pourquoi 1.5? Règle de Tukey, capture ~99.3% des données normales

APPLICATION À NOS DONNÉES:

$Q1 = 55\text{k}$, $Q3 = 208.25\text{k}$, $\text{IQR} = 153.25\text{k}$

Borne inf = $55 - 229.88 = -174.88\text{k} \rightarrow 0$

Borne sup = $208.25 + 229.88 = 438.13\text{k}$



DÉTECTION D'OUTLIERS AVEC LA RÈGLE $1.5 \times \text{IQR}$

Bornes outliers: $Q1 - 1.5 \times \text{IQR}$ et $Q3 + 1.5 \times \text{IQR}$

Pourquoi 1.5? Règle de Tukey, capture ~99.3% des données normales

APPLICATION À NOS DONNÉES:

$Q1 = 55\text{k}$, $Q3 = 208.25\text{k}$, $\text{IQR} = 153.25\text{k}$

Borne inf = $55 - 229.88 = -174.88\text{k} \rightarrow 0$

Borne sup = $208.25 + 229.88 = 438.13\text{k}$

⚠ **Résultat:** $480\text{k} > 438\text{k} \rightarrow \text{OUTLIER!}$ | $320\text{k} \ \& \ 250\text{k} < 438\text{k} \rightarrow \text{Normal}$



COMPARAISON: Z-SCORE VS IQR

Critère	Z-Score	IQR
Basé sur	Moyenne & σ	Quartiles
Sensible outliers?	OUI	NON
Distribution	Normale	Toute
Seuil	$ Z > 3$	Hors $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$
Usage	Symétrique	Asymétrique



COMPARAISON: Z-SCORE VS IQR

Critère	Z-Score	IQR
Basé sur	Moyenne & σ	Quartiles
Sensible outliers?	OUI	NON
Distribution	Normale	Toute
Seuil	$ Z > 3$	Hors $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$
Usage	Symétrique	Asymétrique

💡 **Conseil:** IQR pour distribution inconnue/asymétrique (ex: salaires)



EXERCICE 3: DÉTECTER LES OUTLIERS

Données: 10, 12, 14, 15, 16, 18, 20, 45

Question: Y a-t-il un outlier? Si oui, lequel?

Utilisez la méthode IQR



EXERCICE 3: DÉTECTER LES OUTLIERS

Données: 10, 12, 14, 15, 16, 18, 20, 45

Question: Y a-t-il un outlier? Si oui, lequel?

Utilisez la méthode IQR

Solution:

$$Q1 = 13 \text{ (entre 12 et 14)}$$

$$Q3 = 19 \text{ (entre 18 et 20)}$$

$$IQR = 19 - 13 = 6$$

$$\text{Borne sup} = 19 + 1.5 \times 6 = 28$$

$$45 > 28 \rightarrow \text{Outlier!}$$

PROBLÈME 3: VARIABLES CATÉGORIELLES

TYPE 1: NOMINALE (COUNTRY)

Country	France	Spain	Germany
France	1	0	0
Spain	0	1	0
Germany	0	0	1

→ One-Hot Encoding

PROBLÈME 3: VARIABLES CATÉGORIELLES

TYPE 1: NOMINALE (COUNTRY)

Country	France	Spain	Germany
France	1	0	0
Spain	0	1	0
Germany	0	0	1

→ One-Hot Encoding

TYPE 2: ORDINALE (EDUCATION)

Education	Code
HighSchool	0
Bachelor	1
Master	2
PhD	3

→ Label Encoding (ordre naturel)



EXERCICE 4: ENCODAGE MANUEL

Encodez ces données:

ID	Color	Size
1	Red	Small
2	Blue	Large
3	Red	Medium



EXERCICE 4: ENCODAGE MANUEL

Encodez ces données:

ID	Color	Size
1	Red	Small
2	Blue	Large
3	Red	Medium

SOLUTION:

ID	Red	Blue	Size_Code
1	1	0	0
2	0	1	2
3	1	0	1

Color → One-Hot | Size → Label (S=0, M=1, L=2)



PROBLÈME 4: CORRÉLATION

$$r = \frac{\sum [(x_i - \bar{x})(y_i - \bar{y})]}{\sqrt{[\sum (x_i - \bar{x})^2 \times \sum (y_i - \bar{y})^2]}}$$



PROBLÈME 4: CORRÉLATION

$$r = \frac{\sum [(x_i - \bar{x})(y_i - \bar{y})]}{\sqrt{[\sum (x_i - \bar{x})^2 \times \sum (y_i - \bar{y})^2]}}$$

DONNÉES SIMPLIFIÉES:

Age (x)	Experience (y)
25	3
30	8
35	13
40	18



PROBLÈME 4: CORRÉLATION

$$r = \frac{\sum [(x_i - \bar{x})(y_i - \bar{y})]}{\sqrt{[\sum (x_i - \bar{x})^2 \times \sum (y_i - \bar{y})^2]}}$$

DONNÉES SIMPLIFIÉES:

Age (x)	Experience (y)
25	3
30	8
35	13
40	18

$r = 1.0 \rightarrow$ Corrélation parfaite!

💡 Experience = Age - 22 (relation linéaire exacte)



CALCUL DÉTAILLÉ DE CORRÉLATION

ÉTAPE 1: CALCULER LES MOYENNES

$$\bar{x} = (25 + 30 + 35 + 40) / 4 = 130 / 4 = \mathbf{32.5}$$

$$\bar{y} = (3 + 8 + 13 + 18) / 4 = 42 / 4 = \mathbf{10.5}$$



CALCUL DÉTAILLÉ DE CORRÉLATION

ÉTAPE 1: CALCULER LES MOYENNES

$$\bar{x} = (25 + 30 + 35 + 40) / 4 = 130 / 4 = 32.5$$
$$\bar{y} = (3 + 8 + 13 + 18) / 4 = 42 / 4 = 10.5$$

ÉTAPE 2: CALCULER LES ÉCARTS

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
25	3	-7.5	-7.5	56.25	56.25	56.25
30	8	-2.5	-2.5	6.25	6.25	6.25
35	13	2.5	2.5	6.25	6.25	6.25
40	18	7.5	7.5	56.25	56.25	56.25
Sommes:				125	125	125



CALCUL DÉTAILLÉ DE CORRÉLATION

ÉTAPE 1: CALCULER LES MOYENNES

$$\bar{x} = (25 + 30 + 35 + 40) / 4 = 130 / 4 = 32.5$$
$$\bar{y} = (3 + 8 + 13 + 18) / 4 = 42 / 4 = 10.5$$

ÉTAPE 2: CALCULER LES ÉCARTS

xi	yi	xi - $\bar{x}$	yi - $\bar{y}$	(xi - $\bar{x}$)(yi - $\bar{y}$)	(xi - $\bar{x}$) ²	(yi - $\bar{y}$) ²
25	3	-7.5	-7.5	56.25	56.25	56.25
30	8	-2.5	-2.5	6.25	6.25	6.25
35	13	2.5	2.5	6.25	6.25	6.25
40	18	7.5	7.5	56.25	56.25	56.25
Sommes:				125	125	125

ÉTAPE 3: APPLIQUER LA FORMULE

$$r = 125 / \sqrt{(125 \times 125)} = 125 / \sqrt{15,625} = 125 / 125 = 1.0$$

→ Corrélation parfaite!



PROBLÈME 5: NORMALISATION

STANDARDISATION (Z-SCORE)

$$Z = (X - \mu) / \sigma$$



PROBLÈME 5: NORMALISATION

STANDARDISATION (Z-SCORE)

$$Z = (X - \mu) / \sigma$$

Ex: Age = 44, $\mu = 38$, $\sigma = 7$

$$Z = (44 - 38) / 7 = \mathbf{0.857}$$



PROBLÈME 5: NORMALISATION

STANDARDISATION (Z-SCORE)

$$Z = (X - \mu) / \sigma$$

Ex: Age = 44, $\mu = 38$, $\sigma = 7$

$$Z = (44 - 38) / 7 = \mathbf{0.857}$$

MIN-MAX SCALING

$$X_{\text{norm}} = (X - X_{\text{min}}) / (X_{\text{max}} - X_{\text{min}})$$

Ex: Age = 44, Min = 27, Max = 50

$$X_{\text{norm}} = (44 - 27) / (50 - 27) = \mathbf{0.739}$$



EXERCICE 5: NORMALISATION

Normalisez ces valeurs avec Min-Max:

Données: 10, 15, 20, 25, 30



EXERCICE 5: NORMALISATION

Normalisez ces valeurs avec Min-Max:

Données: 10, 15, 20, 25, 30

Original	Calcul	Normalisé
10	$(10-10)/(30-10)$	0.00
15	$(15-10)/(30-10)$	0.25
20	$(20-10)/(30-10)$	0.50
25	$(25-10)/(30-10)$	0.75
30	$(30-10)/(30-10)$	1.00



PIPELINE CORRECT - ORDRE CRITIQUE!

1. **Analyser** les données
2. **Identifier** les problèmes
3. **Encoder** les catégories (avant split)
4. **Éliminer** les corrélations (avant split)
5. **DIVISER** Train/Test ⚠️ **CRUCIAL!**
6. **Imputer** (fit sur train, transform sur test)
7. **Détecter & Traiter** outliers (sur train seulement)
8. **Normaliser** (fit sur train, transform sur test)



PIPELINE CORRECT - ORDRE CRITIQUE!

1. **Analyser** les données
2. **Identifier** les problèmes
3. **Encoder** les catégories (avant split)
4. **Éliminer** les corrélations (avant split)
5. **DIVISER** Train/Test ⚠️ **CRUCIAL!**
6. **Imputer** (fit sur train, transform sur test)
7. **Détecter & Traiter** outliers (sur train seulement)
8. **Normaliser** (fit sur train, transform sur test)

⚠️ **DANGER:** Ne JAMAIS utiliser les données de test pour calculer moyennes, médianes, ou paramètres de normalisation!



ATTENTION: DATA LEAKAGE!

QU'EST-CE QUE LE DATA LEAKAGE?

Utiliser des informations du test dans l'entraînement



ATTENTION: DATA LEAKAGE!

QU'EST-CE QUE LE DATA LEAKAGE?

Utiliser des informations du test dans l'entraînement

✗ MAUVAIS (LEAKAGE):

1. Calculer moyenne sur TOUT le dataset
 2. Imputer les valeurs manquantes
 3. Diviser en train/test
- Le modèle "connaît" déjà le test! 🤖



ATTENTION: DATA LEAKAGE!

QU'EST-CE QUE LE DATA LEAKAGE?

Utiliser des informations du test dans l'entraînement

✗ MAUVAIS (LEAKAGE):

1. Calculer moyenne sur TOUT le dataset
 2. Imputer les valeurs manquantes
 3. Diviser en train/test
- Le modèle "connaît" déjà le test! 🤖

✓ CORRECT:

1. Diviser en train/test
 2. Calculer moyenne sur TRAIN seulement
 3. Imputer train avec cette moyenne
 4. Imputer test avec la MÊME moyenne (du train)
- Pas de contamination! 🎯



ATTENTION: DATA LEAKAGE!

QU'EST-CE QUE LE DATA LEAKAGE?

Utiliser des informations du test dans l'entraînement

✗ MAUVAIS (LEAKAGE):

1. Calculer moyenne sur TOUT le dataset
 2. Imputer les valeurs manquantes
 3. Diviser en train/test
- Le modèle "connaît" déjà le test! 🤖

✓ CORRECT:

1. Diviser en train/test
 2. Calculer moyenne sur TRAIN seulement
 3. Imputer train avec cette moyenne
 4. Imputer test avec la MÊME moyenne (du train)
- Pas de contamination! 🎯



Règle d'or: `fit()` sur train, `transform()` sur test



DU PAPIER AU CODE

*Maintenant que nous comprenons POURQUOI et COMMENT,
passons au code Python!*

```
import pandas as pd
import numpy as np
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler, LabelEncoder

# Ce que nous avons fait manuellement...
# ... maintenant automatisé!
```

CODE: CHARGEMENT DES DONNÉES

```
# Chargement
import pandas as pd
dataset = pd.read_csv('data/Data.csv')

# Analyse initiale
print(dataset.info())
print(dataset.describe())
print(dataset.isnull().sum())

# Séparation features/target
X = dataset.iloc[:, :-1].values # Toutes sauf dernière
y = dataset.iloc[:, -1].values  # Dernière colonne
```



Correspond à notre analyse papier de l'étape 1

CODE: IMPUTATION

```
from sklearn.impute import SimpleImputer

# Pour Age - Médiane (comme calculé manuellement)
age_imputer = SimpleImputer(strategy='median')
X[:, 1:2] = age_imputer.fit_transform(X[:, 1:2])

# Pour Salary - Moyenne
salary_imputer = SimpleImputer(strategy='mean')
X[:, 2:3] = salary_imputer.fit_transform(X[:, 2:3])

# Vérification
print(f"Age imputé: {X[6, 1]}") # Était manquant
```



Rappel: Nous avons calculé médiane = 38

CODE: TRAITEMENT DES OUTLIERS

```
# Détection avec Z-Score
from scipy import stats
z_scores = np.abs(stats.zscore(X[:, 2]))
outliers = np.where(z_scores > 3)[0]

# Méthode IQR pour capping
Q1 = np.percentile(X[:, 2], 25)
Q3 = np.percentile(X[:, 2], 75)
IQR = Q3 - Q1
upper_bound = Q3 + 1.5 * IQR

# Capping
X[:, 2] = np.where(X[:, 2] > upper_bound,
                  upper_bound, X[:, 2])

print(f"Outliers cappés à: {upper_bound}")
```



Exactement comme notre calcul manuel: 99000

CODE: ENCODAGE CATÉGORIEL

```
# One-Hot pour Country (nominal)
from sklearn.preprocessing import OneHotEncoder
from sklearn.compose import ColumnTransformer

ct = ColumnTransformer(
    transformers=[('encoder', OneHotEncoder(), [0])],
    remainder='passthrough'
)
X = ct.fit_transform(X)

# Label Encoding pour Education (ordinal)
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
le.fit(['HighSchool', 'Bachelor', 'Master', 'PhD'])
X[:, 8] = le.transform(X[:, 8]) # Index après one-hot
```

CODE: ÉLIMINATION DE CORRÉLATION

```
# Calcul de corrélation
correlation = np.corrcoef(X[:, 6], X[:, 9])[0, 1]
print(f"Corrélation Age-Experience: {correlation:.3f}")

# Si corrélation > 0.9, supprimer une variable
if abs(correlation) > 0.9:
    X = np.delete(X, 9, axis=1) # Supprimer Experience
    print("Variable Experience supprimée")

# Alternative: PCA pour réduction
from sklearn.decomposition import PCA
pca = PCA(n_components=0.95) # Garder 95% variance
X_reduced = pca.fit_transform(X)
```

CODE: NORMALISATION

```
# Standardisation (Z-score)
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

print(f"Avant: Age={X[0, 6]}")
print(f"Après: Age={X_scaled[0, 6]:.3f}")

# Alternative: Min-Max
from sklearn.preprocessing import MinMaxScaler
minmax = MinMaxScaler()
X_minmax = minmax.fit_transform(X)

# Comparaison
print(f"Standard:  $\mu=0$ ,  $\sigma=1$ ")
print(f"MinMax: [0, 1]")
```

CODE: DIVISION TRAIN/TEST (CRITIQUE!)

```
# ⚠ DIVISION D'ABORD pour éviter le data leakage!
from sklearn.model_selection import train_test_split

# Division AVANT toute transformation statistique
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

# ENSUITE imputation (fit sur train seulement!)
imputer = SimpleImputer(strategy='mean')
X_train = imputer.fit_transform(X_train)  # fit + transform
X_test = imputer.transform(X_test)        # transform SEULEMENT

# PUIS normalisation (même principe)
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)  # fit + transform
X_test = scaler.transform(X_test)        # transform SEULEMENT
```



JAMAIS fit() sur le test! Toujours transform() seulement

PIPELINE SKLEARN

```
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer

# Pipeline complet de prétraitement
preprocessor = ColumnTransformer(
    transformers=[
        ('num', Pipeline([
            ('imputer', SimpleImputer(strategy='median')),
            ('scaler', StandardScaler())
        ]), [1, 2, 4]), # Colonnes numériques
        ('cat', OneHotEncoder(), [0, 3]) # Catégorielles
    ])

# Application du prétraitement
X_train_processed = preprocessor.fit_transform(X_train)
X_test_processed = preprocessor.transform(X_test)

print("Données prétraitées et prêtes!")
print(f"Shape: {X_train_processed.shape}")
```



EXERCICE FINAL COMPLET

Dataset: clients.csv avec Age, Income, Region, Score

1.  Analysez sur papier
2.  Identifiez les problèmes
3.  Calculez les transformations
4.  Implémentez en Python
5.  Comparez résultats manuel vs code



EXERCICE FINAL COMPLET

Dataset: clients.csv avec Age, Income, Region, Score

1.  Analysez sur papier
2.  Identifiez les problèmes
3.  Calculez les transformations
4.  Implémentez en Python
5.  Comparez résultats manuel vs code



Objectif: Pipeline complet en 30 minutes



FORMULAIRE

Moyenne: $\mu = \Sigma x / n$

Médiane: Valeur centrale après tri

Écart-type: $\sigma = \sqrt{(\Sigma (x - \mu)^2 / n)}$

Z-Score: $Z = (x - \mu) / \sigma$

IQR: $Q3 - Q1$

Min-Max: $(x - \min) / (\max - \min)$

Corrélation: $r \in [-1, 1]$

POINTS CLÉS À RETENIR

POINTS CLÉS À RETENIR

-  **Toujours** analyser avant de coder



POINTS CLÉS À RETENIR

-  **Toujours** analyser avant de coder
-  Comprendre les **mathématiques** derrière



POINTS CLÉS À RETENIR

-  **Toujours** analyser avant de coder
-  Comprendre les **mathématiques** derrière
-  Documenter vos **choix** (moyenne vs médiane)

POINTS CLÉS À RETENIR

-  **Toujours** analyser avant de coder
-  Comprendre les **mathématiques** derrière
-  Documenter vos **choix** (moyenne vs médiane)
-  Ordre important: imputer → encoder → normaliser

POINTS CLÉS À RETENIR

-  **Toujours** analyser avant de coder
-  Comprendre les **mathématiques** derrière
-  Documenter vos **choix** (moyenne vs médiane)
-  Ordre important: imputer → encoder → normaliser
-  Fit sur train, transform sur test

POINTS CLÉS À RETENIR

-  **Toujours** analyser avant de coder
-  Comprendre les **mathématiques** derrière
-  Documenter vos **choix** (moyenne vs médiane)
-  Ordre important: imputer → encoder → normaliser
-  Fit sur train, transform sur test
-  Valider avec des calculs manuels

QUESTIONS?

PRÊTS POUR LE TP TITANIC?



Ressources pour le TP:

- *activite_preprocessing_titanic.md* (guide étape par étape)
- *titanic.csv* (dataset)